

多时空尺度的风力发电预测方法综述

姜兆宇¹ 贾庆山¹ 管晓宏^{1,2}

摘 要 风能是目前世界上装机量较大的可再生能源之一, 风力发电预测的精度直接影响电网的调度与安全运营. 由于电网的调度策略存在多个时间点, 并与涉及的地域范围有关, 本文从多种时间和空间尺度的角度, 综述风力发电预测方法. 风力发电预测一般针对特定的空间范围和时间尺度, 并在有限信息资源的条件下完成, 故本文从上述三个方面综述已有研究成果. 本文首先根据风力发电空间范围, 从单台风力发电机、单一风电场以及风电场群三个空间尺度对研究成果进行梳理. 其次在每个空间尺度上, 根据风电预测是否使用气象信息将研究成果分类, 并根据预测时间尺度将研究成果再次分类. 最后在每个时间尺度上, 根据风电预测存在的挑战, 将已有的研究成果归类. 通过上述梳理, 本文希望可以帮助研究人员找到适合不同风电预测任务场景的方法.

关键词 多尺度, 风力发电, 预测方法, 时间尺度, 空间尺度

引用格式 姜兆宇, 贾庆山, 管晓宏. 多时空尺度的风力发电预测方法综述. 自动化学报, 2019, 45(1): 51–71

DOI 10.16383/j.aas.c180389

A Review of Multi-temporal-and-spatial-scale Wind Power Forecasting Method

JIANG Zhao-Yu¹ JIA Qing-Shan¹ GUAN Xiao-Hong^{1,2}

Abstract Wind power is one of the most installed renewable energy resources in the world, and the accuracy of wind power forecasting method directly affects dispatching and operation safety of the power grid. Since scheduling strategy of the power grid has multiple points and is relative to the geographical scope, this paper summarizes wind power forecasting methods from multi-temporal and multi-spatial perspective. Wind power forecasting usually focuses on specific spatial scale and temporal scale, and is finished with limited information, so this paper classifies researches from three aspects above. Firstly, this paper separates existing wind power forecasting methods into three spatial scales, namely a single wind turbine, a wind farm and a group of wind farms. In each spatial scale, we classify methods by whether using meteorological information, and afterwards by temporal scales. Lastly, in each temporal scale, we also summarize the challenges and achievements. This paper wishes researchers would find suitable methodology when dealing with different wind power forecasting tasks.

Key words Multi-scale, wind power, forecasting method, temporal scale, spatial scale

Citation Jiang Zhao-Yu, Jia Qing-Shan, Guan Xiao-Hong. A review of multi-temporal-and-spatial-scale wind power forecasting method. *Acta Automatica Sinica*, 2019, 45(1): 51–71

随着全球能源危机和环境危机愈发严重, 风能等可再生能源的利用变得愈发重要. 自上世纪末以

来, 全世界风力发电的装机容量在迅速增长, 中国的风力发电装机容量也与日俱增, 呈现迅猛发展的态势. 据中国可再生能源协会发布的《2016 年中国风电装机容量简报》^[1], 中国 2016 年风电新增装机容量 2337 万千瓦, 同比增长 16.08%. 利用好这些风电并使其为电网用电需求服务将对节能减排产生重要影响. 然而, 由于日照、地形、气压等不确定环境因素的影响, 风速和风力发电功率具有较大的不确定性. 为增加风电上网量, 在保证供需实时平衡的条件下, 不仅需要增加调峰机组, 导致发电成本上升, 而且要承担风电电压不稳定给并网输电带来的风险^[2]. 预测风力发电, 可以帮助及时调整调度计划, 找到最优的机组组合方案, 减少调峰发电机组容量, 为风电机组维修保养的时间提供参考^[3–4]. 因此, 提高风力发电预测精度将会降低风能利用成本并提升风力发电接入效率.

现有研究已经从不同的角度总结了风力发电的

收稿日期 2018-06-01 录用日期 2018-10-09

Manuscript received June 1, 2018; accepted October 9, 2018

国家重点研究发展计划 (2016YFB0901900), 国家自然科学基金 (61673229, 61174072, 61222302, 91224008, 61221063, U1301254), 111 创新引智计划 (B06002), 北京市科技新星项目 (xx2014B056) 资助

Supported by National Key Research and Development Program of China (2016YFB0901900), National Natural Science Foundation of China (61673229, 61174072, 61222302, 91224008, 61221063, U1301254), 111 International Collaboration Project of China (B06002), and Program for New Star of Science and Technology in Beijing (xx2014B056)

本文责任编辑 苏宏业

Recommended by Associate Editor SU Hong-Ye

1. 清华大学自动化系智能与网络化系统研究中心, 北京信息科学与技术国家研究中心 北京 100084 2. 西安交通大学智能网络与网络安全教育部重点实验室 西安 710049

1. Center for Intelligent and Networked Systems, Department of Automation, Tsinghua University, Beijing National Research Center for Information Science and Technology, Beijing 100084 2. Key Laboratory of Intelligent Network and Network Security, Ministry of Education, Xi'an Jiao Tong University, Xi'an 710049

预测方法, 包括对风速和风电功率(风电)的预测. 在预测尺度上, 部分研究考虑了时间和空间尺度. 在时间尺度方面, Colak 等^[3] 2012 年综述基于数据挖掘的风电预测方法时考虑到时间尺度. Ata^[5] 综述了人工神经网络在风力发电系统中的应用, 并在总结风电预测时, 根据对象种类和时间尺度对预测方法分类. Okumus 等^[6] 综述了短至 10 分钟、长至 72 小时的不同时间尺度的风速和风电预测方法, 并提出了一个基于神经网络的混合预测方法. 在空间尺度方面, 彭小圣等^[7] 从单个风电场和集群风电场总结了短期和超短期风电功率预测技术. 叶林等^[8] 综述了基于空间相关性的风电功率预测方法, 并将单台风电机的风电预测和风电场的风电预测相联系, 将单个风电场的风电预测和集群风电场的风电预测相联系. Jiang 等^[9] 综述了不同空间和时间尺度下的风速和风电的预测方法, 并对比这些方法的预测精度.

在预测方法上, 通常考虑单一方法和组合方法. 对于单一方法, Kusiak 等^[10]、Foley 等^[11] 和 Jung 等^[12] 都从物理和统计方法两个角度综述了风电预测方法. 另外, Ata^[5] 综述了人工神经网络方法在风电预测中的应用; Colak 等^[3] 综述了基于数据挖掘的风电预测方法; Wang 等^[13] 从模型输入输出个数、迭代步数、模型选择等角度, 综述了现有的风电预测方法; Carta 等^[14] 综述了测量-关联-预测(Measure-correlation-prediction, MCP)^[15] 方法, 介绍这类方法的思想、目标和决定因素, 并从风速、风向以及参考测量点数量等方面, 总结了运用测量-关联的预测方法. 组合方法可回避单一方法的某些局限性. Xiao 等^[16] 和 Tascikaraoglu 等^[17] 从数据预处理、参数选择和优化、误差处理的角度, 综述了预测风速与风电的组合方法. 其中, Xiao 等^[16] 分析了组合方法应用的技术, 包括分解原始信号、选择子方法权重、预测残差等, 并提出了两种方法组合理论. Kusiak 等^[10] 也综述了预测风力发电量的组合方法.

其他方面, Zhang 等^[18] 和 Yan 等^[19] 综述了风电不确定性的预测方法. Zhang 等^[18] 从不确定性的定义、不确定性预测的评价标准、模型的参数估计方法等角度综述了风电预测方法. Yan 等^[19] 从输入数据、预测模型原理、不确定性表达方式和预测时间尺度等角度综述了风电不确定性的预测方法, 并分析了不确定性的来源. Gallego-Castillo 等^[20] 介绍了爬坡预测(Ramp forecasting)^[21] 的定义、爬坡对应的基本气象过程, 并从坡度和爬坡分布概率的角度, 分别综述了风电的爬坡预测方法. Jung 等^[12] 分析了三种风力发电预测需求(区域预测, 概率预测和离岸预测), 并根据每一种需求, 综述了现有风速

和风电预测方法, 总结了影响风力发电预测精度的因素和提高预测精度的典型技术手段.

许多与电网相关的操作, 包括机组组合、计划与调度、负载均衡和负载跟随, 都执行在不同的空间和时间尺度上. 所以, 与这些操作相关的风力发电预测也需要关注不同的空间和时间尺度.

本文结构如下: 首先, 前三节按照空间尺度, 将研究成果分为针对单台风力发电机、单一风电场和风电场群等三类; 其次, 由于不同风力发电预测任务可利用的数据不尽相同, 在根据空间尺度分类后, 将研究成果根据是否使用气象信息分为两类; 接着, 在每个子节中按照时间尺度将研究成果再分为不超过 24 h 的短期预测和超过 24 h 的长期预测两类^[3-4]; 最后, 在每个时间尺度上, 根据风力发电预测存在的挑战, 总结已有的研究成果. 本文还总结了相同时间尺度不同空间尺度、不同时间尺度相同空间尺度上预测方法的关联和差异, 希望可以帮助研究人员在面临不同的风电预测任务时, 找到合适的预测方法.

1 单台风力发电机的发电预测

风力发电机是指可以将风的动能转化为电能的设备. 一般认为, 当风速处于截止风速与额定风速之间时, 单台风机的发电功率大致与风速的三次方成正比^[22]. 因此, 本文将风速预测方法纳入风力发电预测研究之中.

单台风力发电机的预测主要有如下挑战: 1) 单台风力发电机的空间规模小, 局地因素比较复杂, 因而风电的波动较大^[23]. 2) 风电变化规律受局地因素影响而复杂^[23], 缺乏合适的描述模型, 难以为研究人员建立预测模型提供借鉴. 因此研究人员需要不断尝试, 针对不同地理环境和气候环境, 找到影响风电的因素和规律, 建立合适的风力发电预测系统.

1.1 基于风力信息的风力发电预测

风力信息包括风速数据和风力发电功率数据, 本节提到的风力发电预测方法仅基于这些信息进行预测. 在针对单台风力发电机的风电预测模型中, 一般不考虑其他风力发电机的影响和风向变化带来的发电不确定性.

风电具有随机性和间歇性的特点. 据相关数据分析, 单点的风速、风向的统计规律会随着时间尺度的不同而不同^[24]. 下面分别从短期预测和长期预测, 介绍基于风力信息的预测方法.

1.1.1 短期预测

当预测尺度不超过 24 h, 风速的方差和扰动的强度会随着时间尺度的增加而增大^[24]. 这说明风力变化过程在短期具有惯性, 而在时间尺度增加后惯性逐渐消失. 同时, 风速的间歇性主要发生在预测时

间尺度较短的时段^[24]. 这种惯性和间歇性会由于风力发电机所处的地理位置、环境、预测时间和季节的不同而变化, 也会由于噪声的影响而难以探测. 因此, 短期预测主要考虑如何从数据中挖掘这些性质特征. 一般来说, 需要分析历史数据中存在的风力变化模式特征, 并用当前序列匹配其中的某种特征, 得到预测值. 所挖掘的特征也可以用于总结预测值与真实值的误差变化模式, 从而帮助修正预测值. 其框架如图 1 所示.




图 1 单台风机短期风速风电预测方法框架

Fig. 1 Framework of short-term wind power forecasting methods for a single turbine

短期预测的模型通常包括自回归模型、马尔科夫链模型和卡尔曼滤波等. 这些模型都可以实现多步的预测. 在自回归模型方面, 文献 [25] 提出用线性自回归方法预测未来 10 步以内的风速, 时间间隔为 5s, 并提出将原始数据用低通滤波器滤波后, 再计算线性自回归系数, 消除噪声的影响. 文献 [26] 运用风电预测值与历史风速和风力发电功率的线性回归, 并利用相邻 2 天风电相关性较强的特点, 得到了针对单台风力发电机 12h 以内的预测结果. 文献 [27] 运用了泰勒-克里格方法预测风电时间序列, 首先利用风电预测值与历史观测值的相关性随时间的流逝而减弱的特点, 修正样本序列与待估序列的欧氏距离, 接着将时间序列的估计转化为空间未知样本的估计, 以便利用泰勒-克里格方法. 在马尔科夫链模型方面, 文献 [28] 假设风速的短期变化过程是平稳的, 具有马尔科夫性. 通过离散化历史状态和计算状态的转移概率, 再根据马尔科夫性预测未来状态, 最后根据每个状态区间的经验风速分布, 估计风速的预测值. 在卡尔曼滤波方面, 由于卡尔曼滤波可以被看作最优自回归数据处理算法, 而且不需要平稳性假设, 因此在分析风速、风电的自相关性方面十分有效. 早在 1985 年, 文献 [29] 就用卡尔曼滤波做短期的风力发电预测. 卡尔曼滤波也是通过迭代预测多步风速或风电的代表性方法.

1.1.2 长期预测

当预测尺度超过 24h, 预测阶段的风力与观测

到的风力相关性变小, 风力的惯性基本消失. 因此主要考虑如何从风力信息挖掘风速或风电的长期变化趋势. 一般可用变形的自回归滑动平均方法预测长期风电. 文献 [30] 运用指数平滑方法, 认为观测值的权重随时间流逝以负指数速度降低. 并通过估计预测误差, 修正指数平滑方法的预测结果, 预测 20h 后的风速. 文献 [31] 应用分数自回归积分滑动平均 (Autoregressive integrated moving average model, ARIMA) 模型, 将差分参数设成分数, 使模型能够揭示风速的长期相关性, 从而预测 1~2 天以后的风速. 神经网络也可以分析风速时间序列. 文献 [32] 探究了风能动态系统中相空间重构所需的输入数据维数和时间间隔. 通过分析输入数据的主成分, 找到合适的输入维数和时间间隔参数, 并利用神经网络探索输入数据和风电预测值之间的关系, 使模型能够预测长期风电. 由于较短时间尺度的观测数据体现的规律很难在较长的时间尺度内保持不变, 一般通过平滑数据提高观测数据的时间尺度, 以便找到长期变化趋势来预测风电.

1.2 综合风力与其他气象信息的风力发电预测

本节中的其他气象信息包括大气温度、大气压力、湿度、风电场周围地理信息等气象环境的实测信息, 也包括根据这些实测信息和动态方程得到的数值天气预报 (Numerical weather prediction, NWP) 信息. 这些气象信息将与风力信息一起, 作为本节提到的风电预测方法的输入. 下面从短期和长期预测两方面介绍综合风力信息和其他气象信息的风力发电预测方法.

1.2.1 短期预测

在包含气象信息的短期预测方法中, 基于数值天气预报的方法很早就被使用, 因为这是非常直观的一类风力发电预测方法. 风是太阳辐射加热空气的结果. 虽然风的变化较为复杂, 但大气及其附属物的运动仍然遵循许多物理定律, 包括牛顿第二定律、动量守恒定律、热力学第一定律、气体实验定律等^[33]. 这些规律都有数学表达式相对应, 成为构建数值天气预报方程组的基本物理规律. 从 1904 年至今, 人们发展了数值天气预报模式, 逐渐提高计算精度, 提高边界条件和初始条件的质量, 获得了较精确的天气预报结果^[34]. 其中, 风速的预测结果帮助研究人员实现风力发电预测.

利用数值天气预报预测风力发电的步骤如图 2 所示. 1) 利用数值天气预报的中尺度模拟, 得到高空大气中的风速预测数据; 2) 对地形和地面粗糙度建模, 估计当地的风速廓线函数, 并结合数值天气预报结果, 得到风力发电机轮毂高度的风速值. 再利用风力发电机组的风速-功率转化曲线 (理论曲线或

实际拟合曲线), 得到风力发电机组的发电功率预测值^[35]. 此外, 可以根据数值预报结果和实测风速风电数据, 通过计算协方差并利用最小二乘法, 拟合二者之间的关系来预测风速风电. 文献 [36] 拟合了数值天气预报的风速结果与测量风速的关系, 并根据上述关系, 修正风速的预测结果, 进而通过依赖于风向的风速-功率曲线得到风电功率的预测值.

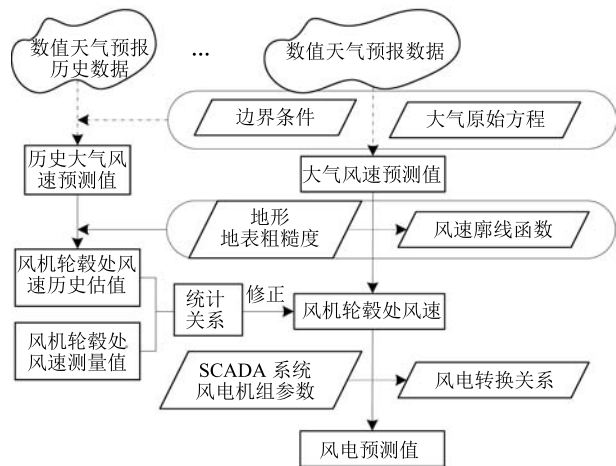


图 2 利用数值天气预报预测单台风机短期风电步骤
Fig. 2 Procedure of short-term wind power forecasting methods for a single turbine using numerical weather prediction

1.2.2 长期预测

数值天气预报作为天气模拟系统, 利用了严格

的物理规律, 只要边界条件和初始条件足够精确, 就能精确预测较长时间范围内气象变量的变化情况. 因此, 在长期预测的要求下, 利用数值天气预报的方法依然有效. 但数值天气预报预测的风速毕竟不能代表风机轮毂处的实际风速, 因此需要根据实际风机的环境, 经过修正后才能使用. 而且风力发电机的风速-功率曲线也不会完全与理想曲线吻合, 需要根据实际场景分析. 文献 [37] 利用模型输出统计, 根据已有的数值天气预报模式 (Eta) 预测的风速数据、3 h 前风速观测数据、6 h 前风速观测数据和当前观测到的风速数据, 做了针对数值天气预报输出风速结果的线性校正公式, 进而得到校正后的风速预测值. 由于风速-功率曲线的不确定性, 文献 [38] 用人工神经网络等工具拟合风速-功率曲线与相关气象因素的关系, 以便在不同的气候环境中更精准地将风速估计值转化为风电估计值.

1.3 单台风力发电机的发电预测方法小结

单台风力发电机通常存在于两种情形: 1) 风力发电机单独存在, 服务区域较小, 服务对象较少; 2) 风力发电机为评估地区风资源而存在. 由于第 2 种情形下的风电预测会在区域风电场群的风电预测中考虑, 本节所述文献主要针对第 1 种情形. 由于单台风力发电机本身功率有限, 无论是否接入电网, 都对电网的影响比较小, 因此已有工作对此涉及较少.

表 1 对比了针对单台风力发电机的不同风电预测方法的输入数据、适用范围和预测误差. 从预测误差上看, 由于国际上对风速及风电的预测误差没有

表 1 单台风力发电机的部分发电预测方法对比
Table 1 Comparison among part of wind power forecasting methods for a single turbine

文献	尺度	方法	输入	适用	误差
[25]	5 s	滑动平均	风速	平稳、线性	—
[26]	12 h	多元回归	风电	平稳、波动小	RMSE: 比常值法低 4.43 %
[27]	24 h	泰勒-克里格	风速	相似序列模式	RMSE: 比 ARIMA 低 15.23 %
[28]	10 min	马氏链、经验分布	风电	平稳	RMSE: 连续 18 h 内 2.36 m/s
[30]	5 d	指数平滑	风速	长期平稳	MAPE: 49.68 %
[31]	2 d	分数-ARIMA	风速	噪声与频率反比	MSE: 比常值法低 42 %
[32]	2 d	主成分分析、相空间重构	风电	长期平稳	NMAE: 约 3 %, 80 % 情况下不超过 12.5 %
[36]	7.5 h	NWP、分段转化	预报风速	测量准、地表均匀	NRMSE: 2.69 %
[37]	36 h	NWP、线性校正	测风速、预报风速	线性校正、长期相关	RMSE: 1.19 m/s
[38]	8 d	神经网络	风速、风电、温度	预报风速转化风电	NRMSE: 2.01 %

注: 误差评价标准一般包括标准均方根误差 (Normalized root mean squared error, NRMSE), 均方根误差 (Root mean squared error, RMSE), 相对百分比平均绝对误差 (Mean absolute percentage error, MAPE), 标准平均绝对误差 (Normalized mean absolute error, NMAE), 平均绝对误差 (Mean absolute error, MAE), 标准均方误差 (Normalized mean squared error, NMSE), 均方误差 (Mean squared error, MSE), 下同.

统一的评价标准(中国国标的评价标准包括: 全天预测结果均方根误差、日平均预测计划曲线准确率、日平均预测计划曲线合格率^[39]), 且使用的数据不尽相同, 预测误差之间没有可比较性。从方法上看, 一般来说, 若只用风力信息做输入, 会分析并利用预测尺度上的风速风电自相关性。若利用数值天气预报, 则重点考虑如何将预报结果转化为风机轮毂处的风速, 并在不同气象环境条件下如何得到精确的风速-功率转化曲线。

2 风电场的风力发电预测

风电场通常包含若干台风力发电机。由于地形限制和尾流效应, 风电机组往往呈现高低错落, 依地势风口而延展的排列。由于风向具有很强的随机性, 原本依据主风向排列的风机并不能时刻达到与风力相匹配的发电功率。因此, 风力场的发电预测不能只考虑单台风机的发电特性, 更要考虑各个风机输出风电的关系以及整个风电场的风电特性。

在针对风电场的发电预测时, 主要有两方面的困难。1) 风电场的风电变化过程依然是非线性且非平稳的。除了风力变化过程非线性且非平稳外, 风力发电机的风速-功率曲线也是非线性且截断的, 风电场的风机相互影响也导致整体风电输出具有一定的随机性和非平稳性。2) 预测模型的参量类型选取和参数计算依然比较复杂。被认为揭示风力非平稳性和随机性的洛伦兹方程组^[40], 虽然给出了这种随机性对应某种奇异吸引子的理论, 但用何种已知变量、如何建立近似真实奇异吸引子的模型仍值得探索。对运用已有知识、处理细节及优化参数等问题解决得好坏, 也将影响风电场风电预测精度的高低。

2.1 基于风力信息的风电场风力发电预测

本节中的风力信息与第 1.1 节中的定义相同, 只考虑风电场的风电数据和某些测量点的风速数据。风电场的风力发电预测是对风电的整体性估计。假设风电场内 N 台风力发电机的发电功率是独立同分布的(虽然有研究表明这样的假设不总是成立^[41]), 那么根据中心极限定理, 平均发电功率的方差是单台风力发电机发电功率方差的 $1/N$ 。因此, 风电场发电功率的随机性和非平稳性与单台风力发电机相比变弱。针对风电场的风电预测是风电预测的主要方向。下面从短期和长期预测两方面介绍风力发电预测的难点, 并针对这些难点, 介绍相应的研究成果。

2.1.1 短期预测

与上一节相同, 短期预测一般预测未来 $0 \sim 24$ h 的风电, 一般为风电机组的控制、载荷跟随等服务, 也可以为经济的负载分配、调节策略提供服务^[3-4]。

由于预测时间尺度较短, 影响风电场短期预测精度的因素一般包含风电过程的间歇性、非平稳性, 以及数据间隔和重构步长的选取。

与单台风力发电机的风电预测不同, 风电场风电过程的间歇性是由于风电场整体风力存在间歇性变化产生的, 而不是受局部地区地形环境因素影响产生的^[23]。风电的间歇性通常表现为风电过程曲线出现上升或下降坡。文献 [42] 利用贝叶斯推断预测带有间歇性的风电场发电情况。首先根据知识和经验, 从数据中挖掘风力变化的平稳性特征。接着通过数据聚类, 计算风力爬坡现象发生的概率。最后利用这些特点, 用贝叶斯推断预测风速和风电。文献 [43] 利用支持向量机预测风速爬坡, 改进基于马尔科夫链和转移概率的风电变化过程描述模型。

风电场的风力情况也具有一定惯性, 在预测尺度较短时, 由于整体效应, 这种惯性会稳定一段时间。因此, 马尔科夫链^[44-45]、自回归(积分)滑动平均模型^[46-47]均可以帮助实现风电的点预测或概率置信区间预测。如果预测时间尺度有所增加, 风力变化过程的平稳性将有所减弱, 此时基于状态转移和线性回归的方法可能不再适用, 取而代之的是深入寻找数据中隐含的高维特征的预测方法, 包括神经网络回归、支持向量回归、回归树等软计算方法^[48-56]。这些方法将过去一段时间的风速、风电或风速风电的某种平均当作输入变量, 把所预测的单步、多步风速或风电当成输出变量, 通过低代价和较为鲁棒的黑箱模型, 模拟这种动态变化关系。有研究人员通过模拟的人工神经网络来模拟风速动态过程, 以克服传统网络难以获得最优结构和陷入局部最优的限制^[57]。也有研究人员利用贝叶斯推断为神经网络参数提供后验知识, 帮助简化网络结构和学习过程^[58], 还有研究人员将不同方法的预测结果进行贝叶斯组合^[59], 或根据预测时间尺度选择不同的方法, 再将预测结果组合^[60]; 或设计不同优化目标的神经网络, 并生成最优权重系数来组合不同神经网络的预测结果^[61]等。

在基于风力信息的预测方法中, 数据间隔和重构步长的选取直接影响风力变化过程的预测效果。文献 [62-64] 研究了历史数据的长度对自回归滑动平均模型、神经网络、支持向量回归等模型预测精度的影响。一些研究者希望通过合适的分解构造不同尺度的序列, 并根据序列的尺度分别建立预测模型, 以提高整体序列的可预测性。文献 [63, 65-72] 讨论了小波分解和经验模态分解在风速风电预测中的应用。文献 [73] 在综合利用经验模态分解和神经网络预测风速时, 着重强调数据预处理的重要性。图 3 综合展示了基于风力信息的风电场短期风电预测方法框架。首先, 根据预测目标时间尺度和风电变化特




图3 基于风力信息风电场短期风电预测方法框架

Fig.3 Framework of short-term wind power forecasting methods for a wind farm with wind information

征,对原始观测序列进行数据重采样或预处理.然后,利用信号特征分析方法,提取风电变化过程的可预测特征,尤其是短期风电变化过程的间歇性特征.再将特征序列输入到经过参数优化后的预测器中,并把各个特征的预测结果相结合,得到所需的风电预测结果.

2.1.2 长期预测

长期风力发电预测一般预测未来 24h 以上的风电,一般为能源交易策略、协调最优的机组组合方案提供参考,并为目前电力市场的安全运行提供服务^[3-4].由于时间尺度比短期预测大大增加,预测区间风速或风电的不稳定性也将增加^[24].因此,选取

合适的数据和模型,寻找不稳定风速或风电变化过程中的规律,消除非平稳性对预测的影响,是长期预测的关键.

为了减少非平稳性逐渐增大给风电预测带来的困难,一种做法就是对输入数据滤波,提高信噪比.然后将处理后的数据作为自回归滑动平均、软计算等方法的输入,得到风速或风电的长期预测结果^[22, 74-82].这种做法通常需要提高输入数据的时间间隔,通过寻找风电长期变化趋势来弥补预测方法只针对单一特征的不足.但数据的波动性也会随着时间间隔的增加而增大,为长期风电趋势的预测增加困难^[24].

如果风电的长期非平稳性较强,一般可以利用

信号分解方法将非平稳序列分解成平稳成分和随机成分. 此时难以预测的随机成分占总体幅值比例较小, 容易预测的平稳成分占总体幅值比例较大. 接下来针对每一组成分, 通过相空间重构分析和回归分析, 训练针对当前成分的预测器. 最后根据这些预测器得到的各个成分的预测值, 并利用信号分解时所用的参数进行重构, 得到长期风速或风电的预测结果, 如图 4 所示. 文献 [83] 先利用小波变换分解观测数据, 然后用模糊自适应谐振网络预测风电, 再用支持向量回归预测模糊自适应谐振网络产生的偏差, 最后利用预测偏差修正预测结果. 文献 [84–85] 用经验模态分解和机器学习相结合的方法预测风速. 文献 [86] 结合信号分解和相空间重构的思想, 针对分解后的每一列原始数据, 设计预测方法及输入结构, 再预测风速. 当然, 这些方法也会对原始数据进行逐时或逐日均值滤波, 以便找到风的长期动态变化趋势.

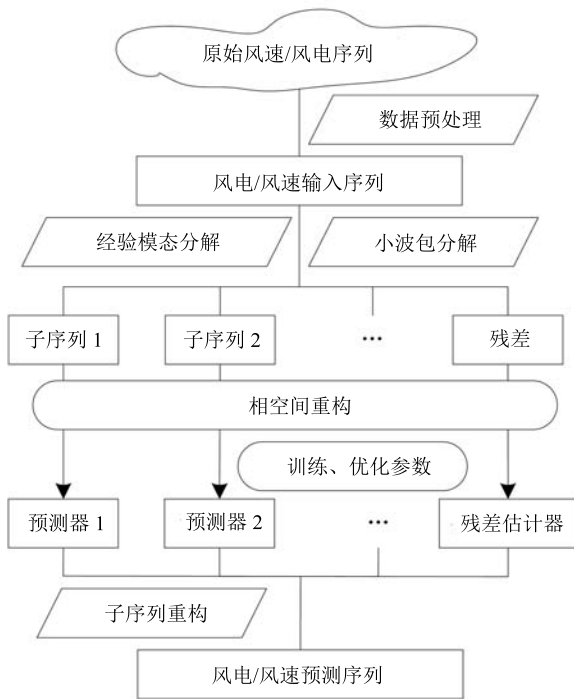


图 4 利用信号分解预测风电场风速风电方法框图

Fig. 4 Framework of wind power forecasting methods for a wind farm using signal decomposition

长期预测更加注重提取原始数据的特征, 以降低非平稳性对预测的干扰. 主成分分析是寻找高维特征的一个常用方法. 通过对归一化的连续时间序列样本组成的延时矩阵进行主成分分析, 得到主成分特征向量, 并以此为输入数据, 利用软计算或 k 近邻分析等方法预测各主成分, 最后利用逆映射和反归一化, 得到风速或风电的预测结果^[87–88]. 对于风能动态过程的不同主成分数据, 可以选择不同的预

测模型^[89]. 文献 [90] 利用主成分分析方法, 筛选对同一时刻的多维输入数据的主成分, 使状态空间减小, 改善了预测算法的输入结构. 文献 [91] 利用基于快速评价的方法来判断输入变量对预测结果的影响大小, 保留影响大的输入变量, 简化了输入数据结构. 自回归分析也可以提取数据变化的特征. 文献 [77] 根据利用自回归分析, 确定输入向量的结构, 再利用非线性拟合或滤波方法预测风速或风电.

然而, 利用上述方法预测长期的风速或风电存在一些明显不足. 1) 时间序列在前向迭代预测或在跨越长时间尺度前向预测的过程中, 其预测误差不断累积并向前传播, 长期预测的效果变差^[92]; 2) 由于模型结构单一, 随着预测时间尺度的增加, 迭代结果将逐渐收敛到平均值或某一固定的频率, 失去预测能力; 3) 由于风电与观测风速在一定范围内呈近似三次函数的关系, 将风速转化为风电的过程会放大风电预测误差; 4) 如果通过提取输入数据特征获得知识的方法建立模型, 会存在特征提取片面, 高维核函数选取不恰当的情况. 这些问题可以通过数据融合和方法综合的方式来解决.

数据融合指综合利用不同时间尺度上的预测结果, 既包含长期的趋势预测, 又包含精细时间尺度的预测. 文献 [93] 利用神经网络识别未来一年的天气模式, 然后再用神经网络预测细节变化. 文献 [94–95] 区分季节变化趋势和日变化趋势, 在季节变化趋势的基础上调整日变化趋势的预测模型参数, 并优化其参数, 再考虑风速变化过程中的爬坡现象, 实现长期预测. 文献 [96] 利用谱分析得到日周期、月周期和季节周期的模式特征, 从而通过去趋势化对原始风速分解, 并利用卡尔曼滤波预测残差部分. 组合两部分的预测结果实现长期风速预测.

方法综合指综合利用不同预测方法或选用不同参数的同一预测方法. 虽然分解原始数据或提取原始数据的主成分可以获得风能动态过程的变化特征, 但由于不能保证特征被完整提取, 针对某种特征的单一预测方法很难取得最优预测效果. 如果用结构或参数不同的方法, 预测同一特征成分, 就可以通过选择或组合不同方法的预测结果, 跳出单一方法容易陷入的局部最优和过拟合情况. 图 5 展示了利用方法综合思想的风电预测框架. 1) 针对历史观测数据, 采用两种不同的预测方法或参数不同的方法预测, 得到若干种预测器; 2) 根据真实结果, 拟合不同预测器的组合预测权重; 3) 将当前所需预测的序列输入到上述不同预测器中, 并将预测结果用上述权重组合, 得到风速或风电的预测值. 文献 [97–98] 采用融合高斯过程和融合神经网络的方法预测同一特征, 以实现风速或风电的长期预测. 不同的是, 文献 [97] 提取了短期非平稳变化特征和季节变化特征;

文献 [98] 根据风力发电机的地理位置, 提取了相似的风电变化过程特征. 也可以用两种不同的方法, 分别预测两种不同特征, 并综合两种特征, 得到超越只针对单一特征的预测结果. 文献 [99] 将自回归积分滑动平均模型和人工神经网络相结合. 其中自回归模型用于预测平稳成分; 人工神经网络用于拟合残差, 预测非平稳成分. 文献 [92] 用高斯过程预测 5 h 以内的短期风电, 再用神经网络预测 5 h 以上、48 h 以内的中长期风电. 文献 [100] 用神经网络组合了基于神经网络的风电预测结果.

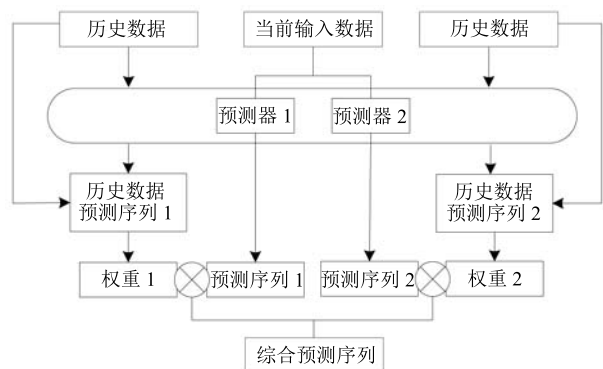


图 5 利用方法综合思想预测风电场风速风电框架

Fig. 5 Framework of wind power forecasting methods for a wind farm with synthesized thought

2.2 综合风力与其他气象信息的风电场风力发电预测

本节中的其他气象信息与第 1.2 节基本一致. 由于可利用的数据种类增多, 预测方法的思路也将改变. 本节侧重从天气变化的角度, 根据物理对象和物理过程, 解释使用某种预测方法的原因. 下面同样从短期和长期预测两方面介绍风力发电预测方法的难点, 并针对这些难点, 介绍相应的研究成果.

2.2.1 短期预测

当预测未来 24 h 以内的发电量时, 天气一般不会有突发性的剧烈变化, 除非遇到导致强风降雨的锋面. 由于锋面预测一般属于长期预测, 本节主要考虑无锋面情形下风力变化过程的短期预测.

风的变化过程与洛伦兹方程组有自然的联系. 一些研究认为预测精度无法提高与测量数据的偏差有关, 因而在传统的预测方法中加入一种洛伦兹扰动, 并以一定比例的扰动项修正预测结果, 以减小预测误差. 这类方法属于利用经验模式分析误差序列的变化趋势. 文献 [101] 通过数据拟合计算洛伦兹扰动与小波神经网络预测结果偏差的相关性系数, 并以此模拟预测偏差的变化情况, 修正预测结果, 实现基于迭代的短期风速预测.

由于增加了气温、湿度、气压以及数值天气预报结果等气象信息, 找到与风电变化过程更相关因素的可能性也变大. 对数据驱动的预测方法来说, 提高输入数据的维度, 更有利于寻找风能动态系统的变化规律. 文献 [102] 利用遗传编程和符号回归, 分析各个天气变量与风电场风电输出功率的关系. 文献 [103] 针对三维风速和气温组成的四元组, 运用自适应滤波预测单步风速. 有研究运用前节提到的特征分析方法, 通过谱聚类或 k 近邻, 从历史数据中找到相似的风力变化过程, 并根据不同的过程设计不同的预测模型, 实现风速或风电的预测. 文献 [104] 针对风速和温度的观测数据, 运用谱聚类和回声状态网络, 分别训练不同类型的数据, 实现风速的预测. 文献 [105] 在利用距离测度分析了相似的天气模式后, 运用几种不同的软计算方法, 建立不同天气时风速的预测模型, 然后根据当前的天气模式, 选择合适的模型预测风速. 文献 [106] 利用 k 近邻学习风速、风向、气压、气温及其历史数据组成的多维向量代表的多种风速变化模式, 并根据当前向量匹配最接近的模式, 实现风速预测. 文献 [41] 通过图学习方法获得风力发电机的发电模式, 根据不同季节和风力爬坡现象获得状态转移矩阵, 从而预测出数小时内的风电功率. 图 6 总结了利用丰富气象数据预测风电场风电的方法框架. 1) 将不同类型的数据用相同的重采样间隔做预处理, 组成了基于历史数据的高维输入向量; 2) 利用相关性分析、主成分分析、经验模式分析和谱分析等方法分析向量及其延时矩阵具有的高维回归特征, 从而确定预测器的参数; 3) 将当前序列经过特征分析后, 输入到训练的预测器中, 得到风速或风电的预测结果.

基于气象学定律的数值天气预报可以帮助提供与真实风速更准确、更相关的风速预测数据. 由于数值天气预报一般每 1~3 h 更新一次, 且预报网格尺度与风电场相当, 所以可用于预测未来 24 h 风电场的风速或风电. 这里对数值天气预报的运用, 既可以与单台风力发电机的数值天气预报预测方法类似, 即先得到降尺度到风机轮毂处高度的风速, 再将风速转化为风电; 也可以有所不同, 即直接根据预报的风速和气象信息, 找到与风电预测值之间的映射关系. 如果利用风速-功率转化曲线, 则会发现由于风电场的风力发电机数量多、效率各异, 整体的风速-功率转化曲线的随机性比单台风力发电机更大. 文献 [107] 提出了两个利用数值天气预报预测风电的方法. 其中一个将数值天气预报预测的风速, 根据不同的风速-功率曲线转化为风电, 再与自回归方法预测的结果组合, 得到最终的风电预测结果. 另一个则将数值天气预报的结果与历史观测数据一起作为输入, 选择不同预测方法以适应不同的时间尺度, 再

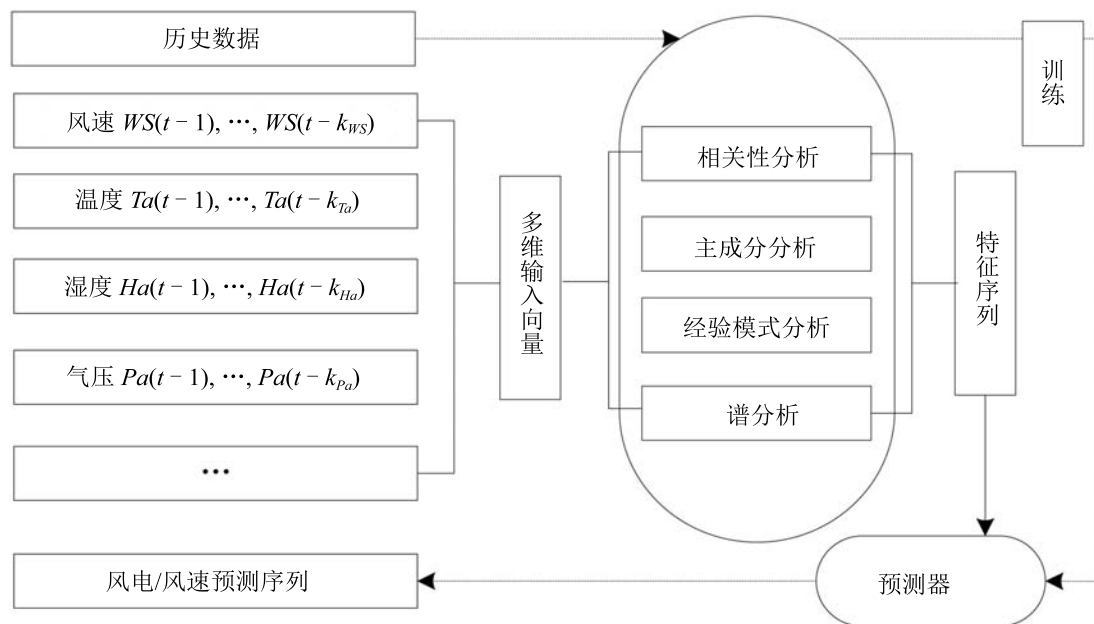


图6 利用丰富气象数据预测风电场短期风电方法框架

Fig.6 Framework of short-term wind power forecasting methods for a wind farm with abundant meteorological information

将各尺度预测结果组合, 得到了高分辨率的风电预测结果. 文献 [108] 利用神经网络, 将数值天气预报提供的风速及其他气象变量一起作为输入预测风电, 并评价不同天气变量对风电预测结果的影响.

2.2.2 长期预测

当预测未来 24 h 以上的发电量时, 数值天气预报更加有用, 因为所用的气象学微分方程与只利用风力信息的预测模型相比, 系统误差更小. 然而, 数值天气预报预测的风速通常不能直接使用, 需要修正. 文献 [109–110] 采用受限的高斯过程、高斯过程及组合协方差函数, 修正数值天气预报提供的风速结果. 文献 [111] 将数值天气预报提供的高空风速与地面测量得到的真实风速用人工神经网络拟合, 得到二者之间的关系. 文献 [38] 利用基于地理信息的风速分布模型, 将数值天气预报预测的风速转化为地面各个点的风速. 文献 [112] 研究不同季节的天气模式对数值天气预报预测结果的影响, 以便可以根据季节, 利用天气变化过程辅助风力发电预测. 文献 [113] 根据数值天气预报系统提供的预测结果, 利用非参数自适应重采样方法, 预测风电的概率置信区间.

研究风电场的风速-功率曲线特征也是利用气象信息预测风力发电的关键. 风速-功率曲线除了根据风机参数或风电场的实际测量值拟合得到外, 也可以利用神经网络等非线性函数将风速及环境参数组成的向量映射为风电^[38, 114]. 与单台风力发电

机不同, 风电场的风速-功率曲线受风向影响较大. 由于风电场的多台风力发电机根据地势按一定的规律排列, 前排风力发电机用叶片切割风, 产生了包含复杂旋涡的尾流, 严重影响尾流后方风力发电机的发电效率. 虽然风电场在最初设计时, 充分考虑了在主风向上避开前排风机的尾流对后排风机的影响, 但当风向发生改变时, 风机主机受感应而转向, 尾流的影响仍不可避免. 因此, 将数值天气预报提供的风速转化为风电时, 需要根据不同的风向拟合不同的风速-功率转化曲线, 以实现较精确的风电预测. 这被称作模型输出统计. 文献 [37, 115] 利用模型输出统计, 消除利用数值天气预报预测风电的系统误差. 文献 [109] 利用受限的高斯分布, 拟合出不同风速风向对应的风电功率分布, 减小风速-功率的转化误差. 图 7 总结了利用数值天气预报预测风电场风电的方法框架, 与处理单台风力发电机的发电预测问题主要有两方面不同. 1) 在风速转化为风电方面, 需要利用模型输出统计来分别得到不同风速风向和其他气象条件下的风电转化关系, 而不仅仅是单一的关系或者单一种类的转化关系; 2) 在对风机轮毂处风速修正方面, 不仅可以利用风速风向信息进行误差拟合, 也可以且需要根据其他气象条件进行高维统计拟合. 这样可以更充分地利用已有信息, 使得风速或风电的预测结果更可靠.

基于气象数据和数值天气预报的长期预测也需考虑如何提取数据中隐藏的可预测特征. 文献 [116] 结合数值天气预报提供的风速数据与历史观测数据,

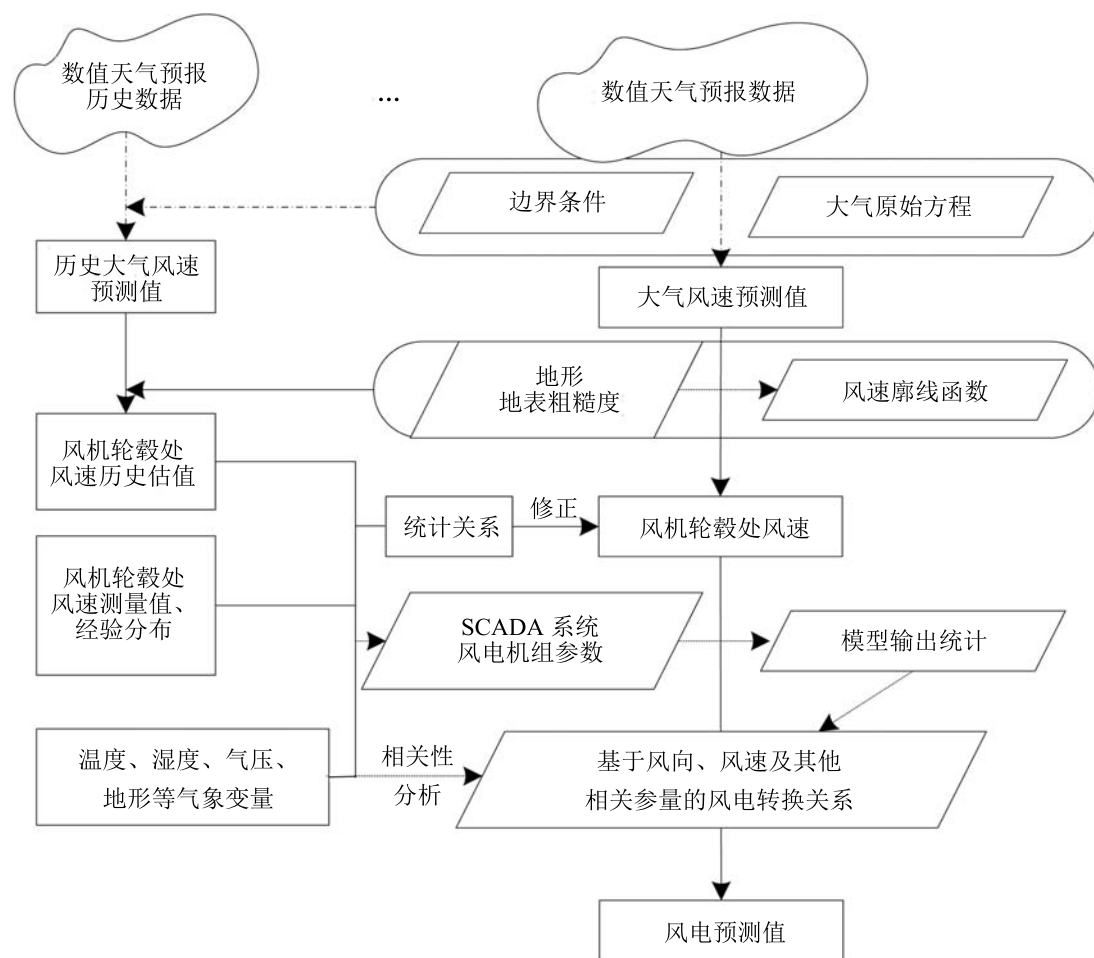


图 7 利用数值天气预报预测风电场长期风电方法框架

Fig. 7 Framework of long-term wind power forecasting methods for a wind farm using numerical weather prediction

用最大似然方法估计模型的参数,建立针对某一时间尺度的自动调谐时变模型,动态预测风力发电.文献[117]利用风力变化过程的相似性,通过 k 近邻搜索寻找相似过程的结果,并将多个预测结果加权得到风速预测值.文献[118]通过聚类分析,找出风速与气温、气压、湿度等天气因素的关联性,利用混沌时间序列预测1个月内的风速,并用相似天气模式下天气变量的聚类值和风速的聚类值,修正风速的预测结果.文献[119]利用不同的软计算方法分别预测风速,获得隐含在数据中的特征.然后融合这些方法的预测结果,得到目标点的风速预测值.文献[120–123]基于数值天气预报研究自适应风电预测方法.通过运用资源分配型网络,预测方法利用的新数据多于旧数据,从而可以快速适应风电场结构的变化.不同的是,文献[120,122]根据风速幅度将输入分成三种类型,而文献[121]根据向量的相似度对输入分类,文献[123]根据天气模式对输入分类.

虽然数值天气预报可以提供多种气象变量的预

测结果,但并非每一种气象变量对即时风电的拟合或未来风电的预测都有作用,有些变量与预测结果的相关性并不大.因此,一些研究挑选输入变量的种类,压缩输入数据集.文献[124]通过相关性分析和冗余分析,精简了输入数据维度.文献[108]分析了不同天气变量对风电预测结果的影响.需要强调的是,输入变量的相关性分析和冗余分析对预测效果有重要影响.文献[32]指出,特定的模型下,不同的输入维度(包括仅考虑风力信息方法中的相关历史步数和输入维度)对应不同的吸引子.引入无关变量和冗余变量会导致预测的变化过程对应的吸引子和真实过程对应的吸引子有系统性偏差;而过少的变量则会导致输入不能完全反映吸引子的特征,也会导致风电预测模型产生系统性偏差.

一些成熟的商业软件也涉及风电长期预测,这些软件通常集成多种方法以满足不同天气模式和地理位置风电场的风电预测需求^[125–127].这样的集成有局限性,因为一般来说,风电预测算法需要根据风

电场的实际环境和测量数据进行差别化设计^[118].

2.3 风电场的风力发电预测方法小结

目前, 绝大多数的风力发电预测工作是针对风电场风力发电机组完成的. 与单台风力发电机相比, 风电场的区域范围较大, 整体发电变化过程具有对地形环境的平均效应, 没有单台风机那样复杂. 虽然无需过多考虑气候环境的细节因素, 但风的惯性、间歇性、非平稳性、周期性、多尺度等特点依然存在并影响风电场风电预测方法的研究进展. 表 2 和表 3 分别对比了只利用风力信息、综合利用风力信息及其他气象信息的风电场风电预测方法.

只用风力信息做输入时, 数据和模型的选择非常重要. 由于风力变化过程非常复杂, 且具有混沌效

应, 很难完全复现. 一般只能根据已有数据和方法, 尽可能找到接近真实风力变化的过程. 数据方面, 主要考虑数据的种类和尺度. 合适的数据种类会使得输入与预测值的相关性增加, 有利于对影响风力变化因素的逼近; 合适的数据尺度会降低数据序列的波动性, 有利于发现数据中包含的风力变化特征. 模型方面, 主要考虑如何发现数据中存在的特征和如何针对特征找到相应的预测方法. 除了逐一尝试外, 自回归积分滑动平均、主成分分析等方法都可以主动发现风速风电序列隐藏的特征, 为相空间重构提供了参数参考. 如果已经发现风的惯性、间歇性、非平稳性、周期性、多尺度等针对性特点, 则需要根据不同特征选择合适的模型, 或组合适合不同特征的模型. 结合选取的数据和模型, 便有机会模拟风力风

表 2 只利用风力信息的风电场的部分发电预测方法对比

Table 2 Comparison among part of wind power forecasting methods merely using wind information for a wind farm

文献	尺度	方法	输入	适用	误差
[42]	90 min	贝叶斯推断	风速	间歇性、先验规律	RMSE: 比常值法低 2.796 %
[43]	60 min	支持向量机、马尔科夫链	风速	间歇性、平稳	MAE: 9.1 %
[44]	10 min	贝叶斯推断、马尔科夫链	风速	平稳、先验规律	RMSE: 比常值法低 4.57 %
[47]	1 h	受限向量 - ARMA	风速、风向	二维平稳	MAE: 0.809 m/s
[48]	15 min	上下界估计网络	风电	平稳	—
[57]	24 h	成组数据推断网络	风速	平稳	MAE: 2.176 m/s
[58]	30 min	贝叶斯推断、神经网络、高斯过程	风速、风电	平稳、高斯性	NRMSE: 16.9 %
[62]	3 h	ARIMA、卡尔曼滤波	风速	稳定、波动小	MAPE: 2.06 %
[68]	3 h	支持向量机、经验小波	风速、风电	非平稳、子序列可预测性	MAPE: 18.41 %
[70]	3 h	小波支持向量机	风速	非平稳	MAPE: 10.76 %
[71]	3 h	经验模态分解、神经网络	风速	非平稳、子序列可预测性	MAPE: 1.87 %
[76]	30 h	自适应小波网络、前馈网络	风速、风电	长期平稳	RMSE: 10.221 %
[77]	1 天	ARIMA、卡尔曼滤波、神经网络	风速	长期平稳、相关	MAPE: 两测试点分别为 16.52 %、8.10 %
[83]	1 天/ 1 周	小波变换、模糊网络	风电	长期平稳、偏差平稳	MAPE: 11.91 % (1 天)/ 15.38 % (1 周) %
[85]	1 天/ 1 月	经验模态分解、神经网络	风速	非平稳、子序列可预测性	MAPE: 17.29 % (1 天)/ 14.92 % (1 月)
[86]	1 天	小波包变换、相空间重构	风速	非平稳、子序列可预测特征	MAPE: 约 20.37 %
[87]	24 h	主成分分析	风速	可预测特征	MAE: 比常值法低 8 % ~ 11 %
[89]	24 h	广义主成分分析	风速	隐藏可预测特征	RMSE: 2.31 ~ 3.76 m/s
[91]	24 h	珊瑚礁优化算法、神经网络	风速	隐藏可预测成分	RMSE: 2.272 m/s
[93]	1 年/ 1 月 / 30 天	多尺度数据融合、神经网络	风速	长短期分别平稳	MAE: 1 年 0.80 m/s, 1 月 0.17 m/s, 30 天 0.64 m/s
[92]	48 h	高斯过程、神经网络	风电	短期惯性、长期间歇性	RMSE: 0.175 m/s
[94]	90 天	Elman 递归网络、季节调整	风速	季节特征、长期平稳	MAPE: 15.32 %
[97]	1 天	高斯混合、高斯回归	风速	短期非平稳、季节特征	MAPE: 0.28 %
[98]	5 天	径向基神经网络、特征分类	风速、风电	有模式特征、长期非平稳	RMSE: 4.78 %
[99]	3 天	ARIMA - 神经网络	风速	基本平稳	MAE: 某处 0.508 m/s

表 3 利用风力信息及其他气象信息的风电场的部分发电预测方法对比

Table 3 Comparison among part of wind power forecasting methods using wind information and meteorological information for a wind farm

文献	尺度	方法	输入	适用	误差
[41]	10 min	图学习、马尔科夫链	地理信息、风速、风电	间歇性、季节性、相似模式	MAPE: 3.65 % ~ 8.22 %
[101]	10 min	洛伦兹扰动-小波神经网络	风速、气压、粗糙度、温度、湿度	预测偏差混沌、洛伦兹特性	RMSE: 比小波神经网络高 50 % ~ 70 %
[102]	30 min	符号回归	风电、湿度、温度、风速	存在隐含相关性	RMSE: 12.6 %
[104]	4 h	谱聚类、回声状态网络	风速、温度	平稳、存在谱特征	MAPE: 8.74 % ~ 11.86 %
[105]	3 h	软计算、距离测度	风速、风向、温度	相似天气模式	MAPE: 9.23 % ~ 10.77 %
[107]	1.5 h	NWP、自回归、神经网络、卡尔曼滤波	风速、风电、气压、温度、预报风速	预报风速转化风电、多模型筛选、平稳	RMSE: 比常值法低 7 % ~ 65 %, 平均约 48 %
[108]	24 h	NWP、神经网络、小波分解	风电、预报风速、温度、气压、湿度	预报风速转化风电、周期性	NMAE: 10.98 % ~ 18.88 %
[109]	24 h	NWP、高斯过程	风速、温度、湿度、气压	高斯性、预报风速转化风电	NMAE: 7.6 % ~ 11.12 %
[111]	48 h	NWP、神经网络	温度、预报风速	地表均匀	MAE: 1.8 m/s
[112]	24 h	NWP、模式分析	预测风速	季节规律	MAE: 2.6 m/s ~ 3.0 m/s
[113]	48 h	NWP、自适应重采样	风电、预报风速	预报风速转化置信区间	NMAE: 不超过 1.5 %
[114]	36 h	NWP、神经网络、帝国竞争算法	风电、预报的风速、湿度、温度	预报风速转化风电	RMSE: 17.2 %
[115]	24 h	NWP、神经网络、卡尔曼滤波	预报的风速、温度、气压、湿度	预报风速转化风电、短期平稳	NRMSE: 16.47 %
[116]	36 h	NWP、卡尔曼滤波、自动调谐	风电、预报风速	短期平稳、风速转化风电	RMSE: 比常值法低约 60 %
[117]	24 h	卡尔曼滤波、 k 近邻分类	风速、风向、气温、气压、相对湿度	相似天气模式、长期非平稳	MAPE: 7.083 %
[118]	31 d	混沌序列、 k 均值聚类	风速、气压、温度、湿度	相似天气模式、长期非平稳	MAPE: 19.21 %
[119]	50 d	软计算、模型融合	风速、温度	非平稳、多模型	NMSE: 0.6515
[123]	36 h	NWP、径向基网络、自组织匹配	风电、预报风速	长期平稳性、预报风速转化风电	NRMSE: 9.77 % ~ 13.44 %
[124]	48 h	NWP、粒子群优化、神经网络	风电、预报的风速、温度、湿度	预报风速转化风电、多模型筛选	NRMSE: 16.58 %
[125]	72 h	卡尔曼滤波、分位点回归	风速、风电、地表粗糙度	长期平稳、地表均匀	NMAE: 约 10 % ~ 20 %

电的动态变化过程,实现优质的风电预测.

如果利用其他气象信息,数据的丰富度会大大提高,找到与风电变化过程更相关数据的可能性也变大.基于气象学定律的数值天气预报可以帮助提供更准确、更相关、尺度更大周期更长的风速预测数据.在此基础上,只需考虑如何将预测数据转化为风机轮毂高度的风速,以及如何将轮毂高度的风速转化为风电,便可以得到更精确的风电预测结果.

3 区域风电场群的风力发电预测

区域风电场群通常指地理空间范围内一定规模风电场的集合.这些风电场往往在相近或相关联的地理位置上,所发出的风电通常整体打包并网传输.

风电场群中各风电场的发电量因区域天气变化过程的连续性而产生相关性.

对于大范围的风电场群风电预测而言,如果将风电场群视作风电场个体的组合,则需要针对每个风电场设计独立的风电预测方法,再将预测结果相加,即叠加法.这类方法的核心是精确预测每一个风电场的发电情况,其方法在第 2 节已经叙述.本节主要考虑将风电场群视作整体的发电预测方法.

3.1 基于风力信息的区域风电场群风力发电预测

风电场群的风电变化过程也具有随机性和间歇性.与风电场不同的是,风电场群风电的间歇性和随机性一般由区域太阳辐射水平和温差决定,具有对

区域的平均效应. 有数据显示, 区域风电场群风电变化过程的波动性比单个风电场小^[128]. 因此, 可以将风电场群视作整体, 用整体平均参数预测风力发电. 由于风电场群中各风电场的发电量具有相关性, 总体风电变化过程也与各风电场相关, 可以通过相关性研究提高风电场群的发电预测水平. 下面从短期预测和长期预测两方面介绍基于风力信息的预测方法.

3.1.1 短期预测

风电场群短期预测的尺度为 $0 \sim 24$ h, 为区域性的能源管理、交易和调度服务, 并为负载平衡、调节提供参考. 此时将风电场群视作整体, 其部分风电预测方法与风电场类似. 在风速预测方面, 文献 [129] 分析主序列的相关性和残余序列依季节变化的自相关性, 获取风速的变化特征, 消除噪声影响. 继而通过极限学习机预测特征成分, 得到针对大范围区域的平均风速预测结果. 在风电预测方面, 文献 [130–133] 利用小波变换提取非平稳风电序列的特征, 再用神经网络预测特征子序列, 最后用小波逆变换得到风电预测值. 其中, 文献 [131–133] 使用基于粒子群优化的自适应模糊神经网络预测特征子序列以替代多层感知器. 文献 [134] 用贝叶斯框架训练神经网络以控制网络的复杂性和预测结果的不确定性, 文献 [135] 利用时间自适应的核密度估计风电的概率置信区间, 并以均值代表风电的预测结果.

3.1.2 长期预测

风电场群长期预测的尺度为 24 h 以上, 为风电机组最优的维修保养时间、机组组合方案和不同类型能源分配方案提供参考. 对此, 已有成果较为匮乏, 研究者大多使用基于神经网络的预测方法^[136–137], 用长期区域内观测的风速平均值作为输入预测风力发电, 以区别于短期预测. 文献 [138] 根据不同地理位置和海拔上的平均风速, 利用人工神经网络, 拟合出一张区域范围内不同位置各个月份的平均风速分布图.

当建设新的风电场时, 需要通过长期预测评估区域的长期风力资源. 这种评估往往需要预测未来数年乃至数十年的风力资源, 因而需要时间范围大致相当的历史观测数据作为参考. 然而, 由于产业的实际需要, 一般针对评估区域的风速测量期不超过 1 年, 而 1 年内的数据很难反映该区域风力资源的长期变化情况. 可利用的数据有周围已经建成的气象测量点 (包括气象站、飞机场、卫星、探空气球、浮标等) 的观测数据, 以及针对评估区域的短期观测数据. 于是, 一种基于测量-关联的预测方法受到重视^[15].

测量-关联-预测的意思是, 利用其他参考点的

测量数据, 根据与目标地点测量数据的相关性, 预测目标地在未能测量的时间范围内相应变量的数值^[14]. 测量-关联-预测的思路主要包含两种: 1) 利用参考点和目标点之间短期可利用的测量数据, 建立二者间的相关性, 并以此关系, 根据参考点的长期数据, 预测目标点的长期风速或风电; 2) 利用参考点短期和长期观测数据, 估计其推演关系, 并将此关系用于目标点, 预测目标点的长期风速或风电, 如图 8 所示. 两种思路各有缺点, 第 1 种思路没有考虑目标点的长期预测值与短期观测值之间的关系; 而第 2 种思路直接假设目标点和参考点的风速风电与参考点的演化关系相同, 而这种假设不具有普适性^[14]. 目前, 第 1 种思路应用范围较广. 文献 [139–140] 均采用第 1 种测量-关联-预测的思路, 估计目标点的长期风速变化. 文献 [139] 还尝试将用于仿真风速的韦伯分布代替统计回归模型, 并比较与统计回归方法的优劣. 文献 [141] 尝试分配可移动测量设备 1 年内在不同目标点的测量时间, 以实现同时估计多点风速. 在此基础上, 根据估计的历史风速数据和测量得到的风速数据, 就可以利用已有的预测方法预测风速的变化趋势, 从而得到未来风力资源的变化情况.

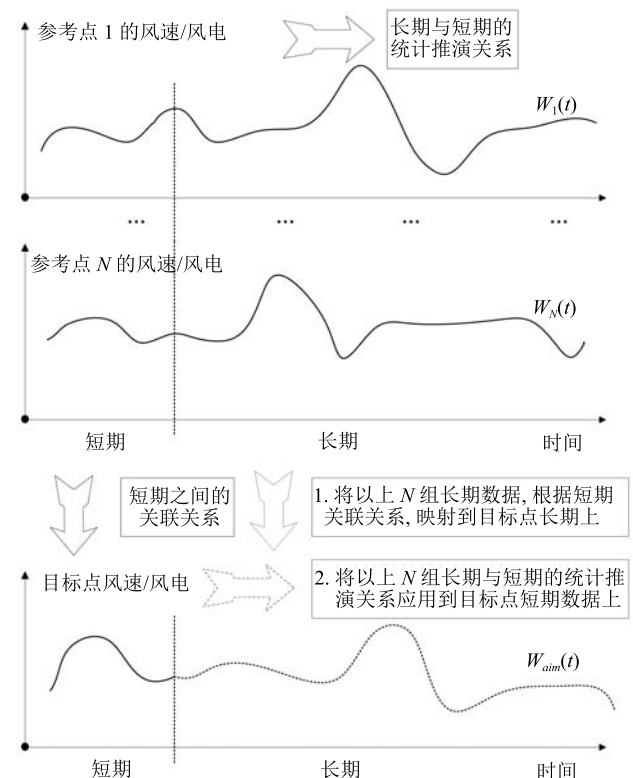


图 8 测量-关联-预测方法示意图

Fig. 8 Schematic diagram of measure-correlation-prediction methods

3.2 综合风力与其他气象信息的区域风电场群风力发电预测

本节中的其他气象信息与第 1.2 节基本一致. 由于区域风电场群的风电过程具有比单台风力发电机和风电场尺度更好的平稳性, 且可利用的数据种类增多, 相同的预测方法可能会有更好的预测效果. 当利用数值天气预报时, 既可以将风电场群看作风电场的总和, 分别预测各个风电场的发电功率并累加; 也可以充分利用风电场群的整体性, 拟合出适合风电场群的风速-功率转化曲线. 下面从短期和长期预测两方面介绍风力发电预测方法的难点, 并针对这些难点, 介绍相应的研究成果.

3.2.1 短期预测

如果从整体角度考虑, 则可以忽略地形的影响, 利用单一特征模式预测并进行误差修正. 这类思路包括整体高维拟合方法和子区域升尺度方法. 预测方法包括: 1) 利用人工神经网络拟合各种天气变量和风速预测值的关系^[142]; 2) 利用局部与整体风力变化模式的相似性, 升尺度预测区域整体风力发电^[143]; 3) 利用数值天气预报的输出值^[144], 组合输出值^[145]预测区域范围内的平均风速并用最优的卡尔曼滤波^[146]或次优的粒子滤波^[35]修正风速预测结果, 继而根据风速-功率曲线或统计风速-功率转化特征^[147]预测目标区域的风电功率.

3.2.2 长期预测

由于拥有数值天气预报结果, 对于考虑空间相关性的测量-关联-预测方法来说, 可以获得更多天气变量的参考值. 文献 [148-149] 利用数值天气预报提供的数据, 根据测量-关联-预测方法, 得到目标点的风速, 继而利用风速-功率转化曲线和扭曲的高斯过程预测风电. 针对新数据的重点利用可以帮助寻找风电的时变特征, 以实现自适应风电预测.

根据丰富的气象数据, 在长期平均滤波的帮助下, 人工神经网络等数据拟合方法可以用来预测未来 1 年至几年的区域风速^[150]和风电^[151]. 在数值天气预报结果和多角度观测数据的帮助下, 测量-关联-预测方法可以更好地展示目标风速或风电与某些天气变量的相关性^[152]. 如果目标区域与参考点的相关性不明显, 可以利用多主成分的最小二乘法等数据特征提取方法寻找相关性, 并以此预测目标区域的风力资源变化趋势^[153].

3.3 区域风电场群的风力发电预测方法小结

目前, 由于建模难度较大、数据相对缺失, 针对区域风电场群的风力发电预测研究较少, 但其对我国风力资源的合理运用和电网的安全运营有重要意义^[7]. 风电场群具有对风电场的平均效应, 其风电变

化过程的波动性比风电场更小, 平稳性比风电场更好. 在选取合适尺度的数据后, 针对风电场的预测方法可以直接用于风电场群的发电预测. 真实测量数据可以辅助修正基于风电场叠加、模式外推和统计升尺度的预测方法, 从而将针对风电场的发电预测方法应用到风电场群的发电预测中. 由于风能评估和风电场选址的需要, 基于测量-关联-预测的风速或风电估计方法有了较大的发展, 并根据环境因素、输入数据和相关方法的不同而产生了较多成果. 由于数值天气预报的空间尺度与区域风电场群的空间尺度相匹配, 数值天气预报结果被广泛用于区域风电场群的风力发电预测中. 表 4 对比了风电场群的风电预测方法.

4 多时空尺度方法分析

风电的预测, 本质上是寻找目标地风电变化过程的规律, 并用数学方法近似描述这种规律, 以实现风电变化过程的推演. 因此, 需要根据不同的空间和时间尺度, 选择合适的数据和方法分析风电变化过程的特点, 并针对这些特点选择合适的数学模型来描述.

4.1 不同空间尺度的预测方法分析

不同空间尺度具有不同的空间特征, 主要包括地理和气候特征. 对于单台风力发电机的空间尺度来说, 风力发电机的风速和风电变化特征受其所处的特定地理位置或地理环境影响较大, 这使得同一风电场中不同风力发电机的风力细节变化规律不完全相同甚至大不相同, 包括间歇性规律和波动性规律. 由于波动性和间歇性是影响风力预测模型建立的重要因素, 针对风电机尺度的预测模型与针对风电场尺度的预测模型理应不完全相同^[128]. 针对风电机尺度的预测模型应多考虑局地的间歇性变化规律^[27], 利用风电机周围的环境测量数据生成并验证预测模型^[38]; 针对风电场尺度的预测模型应多考虑风电场的平稳性变化规律^[83]和风速-功率转化的统计规律^[37], 利用多点测量数据或总体平均数据生成并验证预测模型^[124]. 但在实际工作中, 由于针对单台风力发电机尺度的研究较少, 一些研究并没有区别其方法与风电场尺度中相同预测方法的差异.

相对于区域风电场群的空间尺度来说, 风电场的尺度属于局地尺度. 由于局部地形和相对位置的差异, 组成区域风电场群的各个风电场的发电变化规律可以相同也可以截然不同. 有数据显示区域风电场群风电变化过程的波动性比单个风电场小^[128], 这使得风电场群被视作整体时, 其风电预测更加容易, 预测方法也可以直接套用风电场的预测方法. 由于这类数据一般在欧美的研究中有所体现, 上述规

表 4 风电场群的部分发电预测方法对比

Table 4 Comparison among part of wind power forecasting methods for wind farm group

文献	尺度	方法	输入	适用	误差
[35]	4 h	NWP、粒子群优化、神经网络	风电、预报的风速、温度、湿度	预报风速转化风电、多模型筛选	—
[129]	1 天	极限学习机、季节 ARIMA	风速	惯性、平稳、季节周期	MAPE: 26.68 %
[131]	3 h	自适应神经模糊扰动、小波变换、粒子群优化	风电	非平稳、子序列可预测性	MAPE: 5.81 % 不等
[134]	1 h	神经网络、贝叶斯方法	风电	平稳、先验规律	RMSE: 比常值法高 7 % 不等
[136]	1 月	神经网络	风速	长期平稳	MAPE: 14.13 %
[138]	12 月	神经网络	风速	长期平稳	MAPE: 8.9 %
[139]	12 月	测量关联预测、韦伯分布	风速	空间相关性、分布平稳	NMAE: 4.8 %
[141]	60 天	测量关联预测	风速	空间相关性	RMSE: 0.78 %
[142]	10 min	神经网络	温度、气压、辐射、风速	平稳	MAPE: 4.55 %
[145]	24 h	嵌套 NWP	风电密度、风速分布、预报风速	分布平稳	RMSE: 2 m/s
[146]	24 h	NWP、卡尔曼滤波	风速、预报风速	平稳	MAE: 2.33 m/s
[147]	12 h	NWP、统计升尺度、卡尔曼滤波	风电、风速、预报风速	风速转化风电、局部与总体变化相似	NRMSE: 5.51 %
[148]	12 h	NWP、系数贝叶斯、高斯过程	风速、风电、预测风速	平稳、先验规律、风速转化风电	MAPE: 29.87 %
[149]	6 h	NWP、扭曲高斯分布	风速、风电、预测风速	多模型选择、风速转化风电	MAPE: 10 %
[152]	12 月	NWP、测量关联预测	风速、风电、预测风速	空间相关性、风速转化风电	NMAE: 风速 2.8 %, 风电 7.9 %

律并不一定适用于中国. 目前针对风电场群风电预测的方法主要包括叠加法、模式外推法和统计升尺度法^[7]. 测量-关联-预测弥补了风电预测时数据缺失的不足, 成为评估风电场群风资源普遍使用的模式.

4.2 不同时间尺度的预测方法分析

不同时间尺度的数据拥有截然不同的规律和统计特征. 根据数据分析, 风速的间歇性通常发生在较短时间尺度上; 风速的方差和能量波动性随着时间尺度增加, 先增大后减小; 风速的概率密度分布不随时间尺度而改变; 风向的一致性变化发生在较长的时间尺度上, 风向的突变发生在较短时间尺度上^[24].

由此可见, 在短期预测中, 风速风电的惯性和间歇性是主要特点. 惯性一般可用自回归滑动平均、卡尔曼滤波等方法描述, 而预测方法可以通过自相关分析, 选择合适的数据尺度和重构步长^[62]. 间歇性规律一般可用马尔科夫链、贝叶斯推断等方法来寻找, 并根据幅度大小叠加到风电预测过程中^[44]. 当预测尺度逐渐增大后, 风速风电的波动性增加, 非平稳性提高, 此时滑动平均的预测效果变差, 需要使用对非线性描述能力较强的神经网络来预测风电^[76]. 一些研究希望通过主成分分析、小波分解、经验模

态分解等方法来寻找相关变量或可预测序列^[85], 以提高输入数据在选定模型下的可预测性^[154]. 在长期预测中, 如果数据时间尺度较大, 风速风电的波动性减弱, 可以利用滑动平均和卡尔曼滤波直接预测长期趋势^[112]. 如果数据时间尺度较小, 则利用数据融合^[93]或方法综合^[97], 同时描述风电的长期变化趋势和短期变化细节特征. 对日周期和季节周期的考虑也可融入到风电长期预测方法中^[94].

5 结束语

本文根据空间尺度、时间尺度和输入数据, 划分了近期风力发电预测和风速预测的研究成果, 总结了不同时空尺度和输入数据时, 预测方法重点关注的科学问题和侧重使用的技术手段. 由于时空尺度本身是连续变化的, 为了更清晰地展示时空尺度的变化对风电预测方法的影响, 本文重点总结了相同时间尺度不同空间尺度、不同时间尺度相同空间尺度上预测方法的关联和差异. 由于风电预测一般针对特定的空间范围和时间跨度, 并在有限信息资源的条件下完成, 本文希望通过这样的思路, 帮助风电预测研究人员找到适合不同风电预测任务的预测方法, 也希望这些方法可以帮助研究人员完成信息

物理融合能源系统的各项研究,例如高精度传感器布设位置优化^[155]、建筑群微电网系统建模与效益优化^[156-157]等。

除了找到可用的预测方法,研究人员还需要思考如何提高风电预测水平。针对预测目标固定的工程任务来说,可以改进的要素主要包括可利用的信息资源和可使用的预测模型两部分。1) 在可利用的信息资源方面,需要与气象部门联合积累当地不同时间尺度和不同空间分辨率的数值天气预报信息,需要建设更多测量点以积累丰富、可靠、分辨率高的气象测量信息。充分的信息可以帮助提取更多的映射特征,从而便于研究人员筛选主要影响因素,过滤冗余因素,提高给定模型下预测关系拟合的准确性。2) 在可使用的预测模型方面,需要积累不同模型在多种时间和空间尺度上提取的风力变化特征和映射特征,建立基于模型的特征库。充分的特征有助于匹配当前风力发电的变化模式,在地理环境相对不变的情况下,便于研究人员从模型库中筛选适合当前特征的预测模型,从而有助于动态筛选并组合模型以提高风电预测水平。

References

- Chinese Wind Energy Association. Statistics of Installed Wind Power Capacity of China in 2016. *Wind Energy*, 2017, **2**: 32–44
(中国可再生能源学会风能专委会. 2016 年中国风电装机容量统计. 风能, 2017, **2**: 32–44)
- Bouffard F, Galiana F D. Stochastic security for operations planning with significant wind power generation. In: Proceedings of the 2008 IEEE Power and Energy Society General Meeting-Conversion and Delivery of Electrical Energy in the 21st Century. Pittsburgh, PA, USA: IEEE, 2008. 1–11
- Colak I, Sagirolu S, Yesilbudak M. Data mining and wind power prediction: a literature review. *Renewable Energy*, 2012, **46**: 241–247
- Soman S S, Zareipour H, Malik O, Mandal P. A review of wind power and wind speed forecasting methods with different time horizons. In: Proceedings of the 2010 North American Power Symposium (NAPS). Arlington, Texas, USA: IEEE, 2010. 1–8
- Ata R. Artificial neural networks applications in wind energy systems: a review. *Renewable and Sustainable Energy Reviews*, 2015, **49**: 534–562
- Okumus I, Dinler A. Current status of wind energy forecasting and a hybrid method for hourly predictions. *Energy Conversion and Management*, 2016, **123**: 362–371
- Peng Xiao-Sheng, Xiong Lei, Wen Jin-Yu, Cheng Shi-Jie, Deng Di-Yuan, Feng Shuang-Lei, et al. A summary of the state of the art for short-term and ultra-short-term wind power prediction of regions. *Proceedings of the CSEE*, 2016, **36**(23): 6315–6326
(彭小圣, 熊磊, 文劲宇, 程时杰, 邓迪元, 冯双磊, 等. 风电集群短期及超短期功率预测精度改进方法综述. 中国电机工程学报, 2016, **36**(23): 6315–6326)
- Ye Lin, Zhao Yong-Ning. A review on wind power prediction based on spatial correlation approach. *Automation of Electric Power Systems*, 2014, **38**(14): 126–135
(叶林, 赵永宁. 基于空间相关性的风电功率预测研究综述. 电力系统自动化, 2014, **38**(14): 126–135)
- Jiang Z Y, Jia Q S, Guan X H. Review of wind power forecasting methods: from multi-spatial and temporal perspective. In: Proceedings of the 36th Chinese Control Conference. Dalian, China: IEEE, 2017. 10576–10583
- Kusiak A, Zhang Z J, Verma A. Prediction, operations, and condition monitoring in wind energy. *Energy*, 2013, **60**: 1–12
- Foley A M, Leahy P G, Marvuglia A, McKeogh E J. Current methods and advances in forecasting of wind power generation. *Renewable Energy*, 2012, **37**(1): 1–8
- Jung J, Broadwater R P. Current status and future advances for wind speed and power forecasting. *Renewable and Sustainable Energy Reviews*, 2014, **31**: 762–777
- Wang J Z, Song Y L, Liu F, Hou R. Analysis and application of forecasting models in wind power integration: a review of multi-step-ahead wind speed forecasting models. *Renewable and Sustainable Energy Reviews*, 2016, **60**: 960–981
- Carta J A, Velázquez S, Cabrera P. A review of measure-correlate-predict (MCP) methods used to estimate long-term wind characteristics at a target site. *Renewable and Sustainable Energy Reviews*, 2013, **27**: 362–400
- Ye Lin, Yang Dan-Ping, Zhao Yong-Ning. Overview of wind resource measure-correlate-predict methods for wind farms. *Automation of Electric Power Systems*, 2016, **40**(3): 140–151
(叶林, 杨丹萍, 赵永宁. 风电场风能资源评估的测量-关联-预测方法综述. 电力系统自动化, 2016, **40**(3): 140–151)
- Xiao L, Wang J Z, Dong Y, Wu J. Combined forecasting models for wind energy forecasting: a case study in China. *Renewable and Sustainable Energy Reviews*, 2015, **44**: 271–288
- Tascikaraoglu A, Uzunoglu M. A review of combined approaches for prediction of short-term wind speed and power. *Renewable and Sustainable Energy Reviews*, 2014, **34**: 243–254
- Zhang Y, Wang J X, Wang X F. Review on probabilistic forecasting of wind power generation. *Renewable and Sustainable Energy Reviews*, 2014, **32**: 255–270
- Yan J, Liu Y Q, Han S, Wang Y M, Feng S L. Reviews on uncertainty analysis of wind power forecasting. *Renewable and Sustainable Energy Reviews*, 2015, **52**: 1322–1330
- Gallego-Castillo C, Cuerva-Tejero A, Lopez-Garcia O. A review on the recent history of wind power ramp forecasting. *Renewable and Sustainable Energy Reviews*, 2015, **52**: 1148–1157
- Ouyang Ting-Hui, Zha Xiao-Ming, Qin Liang, Xiong Yi, Huang He-Ming. Wind power ramps prediction method based on amendment of similar events. *Proceedings of the CSEE*, 2017, **37**(2): 572–580

- (欧阳庭辉, 查晓明, 秦亮, 熊一, 黄鹤鸣. 基于相似性修正的风电功率爬坡事件预测方法. 中国电机工程学报, 2017, **37**(2): 572–580)
- 22 Mohammadi K, Shamshirband S, Yee P L, Petković D, Zamani M, Ch S. Predicting the wind power density based upon extreme learning machine. *Energy*, 2015, **86**: 232–239
- 23 Yan J, Zhang H, Liu Y Q, Han S, Li L, Lu Z X. Forecasting the high penetration of wind power on multiple scales using multi-to-multi mapping. *IEEE Transactions on Power Systems*, 2018, **33**(3): 3276–3284
- 24 Wang Y, Meng Q H, Li H X, Zeng M. Multi-scale analysis of single-point wind signals in outdoor near-surface environments. In: Proceedings of the 31st Chinese Control Conference. Hefei, China: IEEE, 2012. 3880–3885
- 25 Riahy G H, Abedi M. Short term wind speed forecasting for wind turbine applications using linear prediction method. *Renewable Energy*, 2008, **33**(1): 35–41
- 26 Croonenbroeck C, Dahl C M. Accurate medium-term wind power forecasting in a censored classification framework. *Energy*, 2014, **73**: 221–232
- 27 Liu H P, Shi J, Erdem E. Prediction of wind speed time series using modified Taylor Kriging method. *Energy*, 2010, **35**(12): 4870–4879
- 28 Tang J, Brouste A, Tsui K L. Some improvements of wind speed Markov chain modeling. *Renewable Energy*, 2015, **81**: 52–56
- 29 Bossanyi E A. Short-term wind prediction using Kalman filters. *Wind Engineering*, 1985, **9**(1): 1–8
- 30 Cadenas E, Jaramillo O A, Rivera W. Analysis and forecasting of wind velocity in chetumal, quintana roo, using the single exponential smoothing method. *Renewable Energy*, 2010, **35**(5): 925–930
- 31 Kavasseri R G, Seetharaman K. Day-ahead wind speed forecasting using f-ARIMA models. *Renewable Energy*, 2009, **34**(5): 1388–1393
- 32 Han L, Romero C E, Yao Z. Wind power forecasting based on principle component phase space reconstruction. *Renewable Energy*, 2015, **81**: 737–744
- 33 Chen De-Hui, Xue Ji-Shan. An overview on recent progresses of the operational numerical weather prediction models. *Acta Meteorologica Sinica*, 2004, **62**(5): 623–633 (陈德辉, 薛纪善. 数值天气预报业务模式现状与展望. 气象学报, 2004, **62**(5): 623–633)
- 34 Wang Jian-Cheng, Yang Ping, Yang Xi. Research on wind power prediction modeling based on numerical weather prediction. *Renewable Energy Resources*, 2013, **31**(2): 34–38 (王建成, 杨苹, 杨曦. 基于数值天气预报的风电功率预测建模研究. 可再生能源, 2013, **31**(2): 34–38)
- 35 Li P, Guan X H, Wu J. Aggregated wind power generation probabilistic forecasting based on particle filter. *Energy Conversion and Management*, 2015, **96**: 579–587
- 36 Khalid M, Savkin A V. A method for short-term wind power prediction with multiple observation points. *IEEE Transactions on Power Systems*, 2012, **27**(2): 579–586
- 37 Lazić L, Pejanović G, Živković M, Ilić L. Improved wind forecasts for wind power generation using the Eta model and MOS (model output statistics) method. *Energy*, 2014, **73**: 567–574
- 38 Peng H W, Liu F R, Yang X F. A hybrid strategy of short term wind power prediction. *Renewable Energy*, 2013, **50**: 590–595
- 39 National Energy Administration. The interim measures on wind power forecasting management. *Solar Energy*, 2011, (14): 6–7 (国家能源局. 风电场功率预测预报管理暂行办法. 太阳能, 2011, (14): 6–7)
- 40 Zhou Xian-Chun, Lin Wan-Tao, Lin Yi-Hua, Yao Jing-Sun, Mo Jia-Qi. A method of solving a class of disturbed Lorenz system. *Acta Physica Sinica*, 2011, **60**(11): 110207 (周先春, 林万涛, 林一骅, 姚静菀, 莫嘉琪. 一类扰动洛伦兹系统的解法. 物理学报, 2011, **60**(11): 110207)
- 41 He M, Yang L, Zhang J S, Vittal V. A spatio-temporal analysis approach for short-term forecast of wind farm generation. *IEEE Transactions on Power Systems*, 2014, **29**(4): 1611–1622
- 42 Jiang Y, Song Z, Kusiak A. Very short-term wind speed forecasting with Bayesian structural break model. *Renewable Energy*, 2013, **50**: 637–647
- 43 Yang L, He M, Zhang J S, Vittal V. Support-vector-machine-enhanced Markov model for short-term wind power forecast. *IEEE Transactions on Sustainable Energy*, 2015, **6**(3): 791–799
- 44 Song Z, Jiang Y, Zhang Z J. Short-term wind speed forecasting with Markov-switching model. *Applied Energy*, 2014, **130**: 103–112
- 45 Kani S A P, Ardehali M M. Very short-term wind speed prediction: a new artificial neural network-Markov chain model. *Energy Conversion and Management*, 2011, **52**(1): 738–745
- 46 Sfetsos A. A novel approach for the forecasting of mean hourly wind speed time series. *Renewable Energy*, 2002, **27**(2): 163–174
- 47 Erdem E, Shi J. ARMA based approaches for forecasting the tuple of wind speed and direction. *Applied Energy*, 2011, **88**(4): 1405–1414
- 48 Khosravi A, Nahavandi S. Combined nonparametric prediction intervals for wind power generation. *IEEE Transactions on Sustainable Energy*, 2013, **4**(4): 849–856
- 49 Khosravi A, Nahavandi S. An optimized mean variance estimation method for uncertainty quantification of wind power forecasts. *International Journal of Electrical Power and Energy Systems*, 2014, **61**: 446–454
- 50 Chen K L, Yu J. Short-term wind speed prediction using an unscented Kalman filter based state-space support vector regression approach. *Applied Energy*, 2014, **113**: 690–705
- 51 Monfared M, Rastegar H, Kojabadi H M. A new strategy for wind speed forecasting using artificial intelligent methods. *Renewable Energy*, 2009, **34**(3): 845–848

- 52 Chitsaz H, Amjady N, Zareipour H. Wind power forecast using wavelet neural network trained by improved Clonal selection algorithm. *Energy Conversion and Management*, 2015, **89**: 588–598
- 53 Li G, Shi J. On comparing three artificial neural networks for wind speed forecasting. *Applied Energy*, 2010, **87**(7): 2313–2320
- 54 Zhou J Y, Shi J, Li G. Fine tuning support vector machines for short-term wind speed forecasting. *Energy Conversion and Management*, 2011, **52**(4): 1990–1998
- 55 Troncoso A, Salcedo-Sanz S, Casanova-Mateo C, Riquelme J C, Prieto L. Local models-based regression trees for very short-term wind speed prediction. *Renewable Energy*, 2015, **81**: 589–598
- 56 Lahouar A, Slama J B H. Hour-ahead wind power forecast based on random forests. *Renewable Energy*, 2017, **109**: 529–541
- 57 Abdel-Aal R E, Elhadidy M A, Shaahid S M. Modeling and forecasting the mean hourly wind speed time series using GMDH-based abductive networks. *Renewable Energy*, 2009, **34**(7): 1686–1699
- 58 Blonbou R. Very short-term wind power forecasting with neural networks and adaptive Bayesian learning. *Renewable Energy*, 2011, **36**(3): 1118–1124
- 59 Li G, Shi J, Zhou J Y. Bayesian adaptive combination of short-term wind speed forecasts from neural network models. *Renewable Energy*, 2011, **36**(1): 352–359
- 60 Shi J, Guo J M, Zheng S T. Evaluation of hybrid forecasting approaches for wind speed and power generation time series. *Renewable and Sustainable Energy Reviews*, 2012, **16**(5): 3471–3480
- 61 Wang J Z, Heng J N, Xiao L Y, Wang C. Research and application of a combined model based on multi-objective optimization for multi-step ahead wind speed forecasting. *Energy*, 2017, **125**: 591–613
- 62 Liu H, Tian H Q, Li Y F. Comparison of two new ARIMA-ANN and ARIMA-Kalman hybrid methods for wind speed prediction. *Applied Energy*, 2012, **98**: 415–424
- 63 Liu H, Tian H Q, Pan D F, Li Y F. Forecasting models for wind speed using wavelet, wavelet packet, time series and Artificial Neural Networks. *Applied Energy*, 2013, **107**: 191–208
- 64 Bigdeli N, Afshar K, Gazafroudi A S, Ramandi M Y. A comparative study of optimal hybrid methods for wind power prediction in wind farm of Alberta, Canada. *Renewable and Sustainable Energy Reviews*, 2013, **27**: 20–29
- 65 Liu H, Tian H Q, Chen C, Li Y F. A hybrid statistical method to predict wind speed and wind power. *Renewable Energy*, 2010, **35**(8): 1857–1861
- 66 Liu H, Tian H Q, Li Y F. Four wind speed multi-step forecasting models using extreme learning machines and signal decomposing algorithms. *Energy Conversion and Management*, 2015, **100**: 16–22
- 67 Liu H, Tian H Q, Li Y F. Comparison of new hybrid FEEMD-MLP, FEEMD-ANFIS, Wavelet Packet-MLP and Wavelet Packet-ANFIS for wind speed predictions. *Energy Conversion and Management*, 2015, **89**: 1–11
- 68 Hu J M, Wang J Z, Ma K L. A hybrid technique for short-term wind speed prediction. *Energy*, 2015, **81**: 563–574
- 69 Liu H, Tian H Q, Chen C, Li Y F. An experimental investigation of two Wavelet-MLP hybrid frameworks for wind speed prediction using GA and PSO optimization. *International Journal of Electrical Power and Energy Systems*, 2013, **52**: 161–173
- 70 Zeng J W, Qiao W. Short-term wind power prediction using a wavelet support vector machine. *IEEE Transactions on Sustainable Energy*, 2012, **3**(2): 255–264
- 71 Liu H, Chen C, Tian H Q, Li Y F. A hybrid model for wind speed prediction using empirical mode decomposition and artificial neural networks. *Renewable Energy*, 2012, **48**: 545–556
- 72 Liu H, Tian H Q, Li Y F, Zhang L. Comparison of four Adaboost algorithm based artificial neural networks in wind speed predictions. *Energy Conversion and Management*, 2015, **92**: 67–81
- 73 Zhang W Y, Qu Z X, Zhang K Q, Mao W Q, Ma Y N, Fan X. A combined model based on CEEMDAN and modified flower pollination algorithm for wind speed forecasting. *Energy Conversion and Management*, 2017, **136**: 439–451
- 74 De Giorgi M G, Ficarella A, Tarantino M. Error analysis of short term wind power prediction models. *Applied Energy*, 2011, **88**(4): 1298–1311
- 75 Quan H, Srinivasan D, Khosravi A. Short-term load and wind power forecasting using neural network-based prediction intervals. *IEEE Transactions on Neural Networks and Learning Systems*, 2014, **25**(2): 303–315
- 76 Bhaskar K, Singh S N. AWWN-assisted wind power forecasting using feed-forward neural network. *IEEE Transactions on Sustainable Energy*, 2012, **3**(2): 306–315
- 77 Shukur O B, Lee M H. Daily wind speed forecasting through hybrid KF-ANN model based on ARIMA. *Renewable Energy*, 2015, **76**: 637–647
- 78 Cadenas E, Rivera W. Wind speed forecasting in the south coast of Oaxaca, México. *Renewable Energy*, 2007, **32**(12): 2116–2128
- 79 Guo Z H, Zhao J, Zhang W Y, Wang J Z. A corrected hybrid approach for wind speed prediction in Hexi Corridor of China. *Energy*, 2011, **36**(3): 1668–1679
- 80 Ren C, An N, Wang J Z, Li L, Hu B, Shang D. Optimal parameters selection for BP neural network based on particle swarm optimization: a case study of wind speed forecasting. *Knowledge-Based Systems*, 2014, **56**: 226–239
- 81 Bessa R J, Miranda V, Gama J. Entropy and correntropy against minimum square error in offline and online three-day ahead wind power forecasting. *IEEE Transactions on Power Systems*, 2009, **24**(4): 1657–1666
- 82 Chang G W, Lu H J, Chang Y R, Lee Y D. An improved neural network-based approach for short-term wind speed and power forecast. *Renewable Energy*, 2017, **105**: 301–311

- 83 Haque A U, Nehrir M H, Mandal P. A hybrid intelligent model for deterministic and quantile regression approach for probabilistic wind power forecasting. *IEEE Transactions on Power Systems*, 2014, **29**(4): 1663–1672
- 84 Hu J M, Wang J Z, Zeng G W. A hybrid forecasting approach applied to wind speed time series. *Renewable Energy*, 2013, **60**: 185–194
- 85 Guo Z H, Zhao W G, Lu H Y, Wang J Z. Multi-step forecasting for wind speed using a modified EMD-based artificial neural network model. *Renewable Energy*, 2012, **37**(1): 241–249
- 86 Wang J Z, Wang Y, Jiang P. The study and application of a novel hybrid forecasting model — a case study of wind speed forecasting in China. *Applied Energy*, 2015, **143**: 472–488
- 87 Skittides C, Früh W G. Wind forecasting using principal component analysis. *Renewable Energy*, 2014, **69**: 365–374
- 88 Yeh W C, Yeh Y M, Chang P C, Ke Y C, Chung V. Forecasting wind power in the Mai Liao Wind Farm based on the multi-layer perceptron artificial neural network model with improved simplified swarm optimization. *International Journal of Electrical Power and Energy Systems*, 2014, **55**: 741–748
- 89 Hu Q H, Su P Y, Yu D R, Liu J F. Pattern-based wind speed prediction based on generalized principal component analysis. *IEEE Transactions on Sustainable Energy*, 2014, **5**(3): 866–874
- 90 Kusiak A, Zheng H Y, Song Z. Models for monitoring wind farm power. *Renewable Energy*, 2009, **34**(3): 583–590
- 91 Salcedo-Sanz S, Pastor-Sánchez A, Del Ser J, Prieto L, Geem Z W. A coral reefs optimization algorithm with harmony search operators for accurate wind speed prediction. *Renewable Energy*, 2015, **75**: 93–101
- 92 Lee D, Baldick R. Short-term wind power ensemble prediction based on Gaussian processes and neural networks. *IEEE Transactions on Smart Grid*, 2014, **5**(1): 501–510
- 93 Azad H B, Mekhilef S, Ganapathy V G. Long-term wind speed forecasting and general pattern recognition using neural networks. *IEEE Transactions on Sustainable Energy*, 2014, **5**(2): 546–553
- 94 Wang J Z, Qin S S, Zhou Q P, Jiang H Y. Medium-term wind speeds forecasting utilizing hybrid models for three different sites in Xinjiang, China. *Renewable Energy*, 2015, **76**: 91–101
- 95 Zhang W Y, Wu J, Wang J Z, Zhao W G, Shen L. Performance analysis of four modified approaches for wind speed forecasting. *Applied Energy*, 2012, **99**: 324–333
- 96 Akçay H, Filik T. Short-term wind speed forecasting by spectral analysis from long-term observations with missing values. *Applied Energy*, 2017, **191**: 653–662
- 97 Yu J, Chen K L, Mori J, Rashid M M. A Gaussian mixture copula model based localized Gaussian process regression approach for long-term wind speed prediction. *Energy*, 2013, **61**: 673–686
- 98 Liu Y Q, Gao X L, Yan J, Han S, Infield D G. Clustering methods of wind turbines and its application in short-term wind power forecasts. *Journal of Renewable and Sustainable Energy*, 2014, **6**(5): 053119
- 99 Cadenas E, Rivera W. Wind speed forecasting in three different regions of Mexico, using a hybrid ARIMA-ANN model. *Renewable Energy*, 2010, **35**(12): 2732–2738
- 100 Liu J Q, Wang X R, Lu Y. A novel hybrid methodology for short-term wind power forecasting based on adaptive neuro-fuzzy inference system. *Renewable Energy*, 2017, **103**: 620–629
- 101 Zhang Y G, Yang J Y, Wang K C, Wang Z P, Wang Y D. Improved wind prediction based on the Lorenz system. *Renewable Energy*, 2015, **81**: 219–226
- 102 Vladislavleva E, Friedrich T, Neumann F, Wagner M. Predicting the energy output of wind farms based on weather data: important variables and their correlation. *Renewable Energy*, 2013, **50**: 236–243
- 103 Took C C, Strbac G, Aihara K, Mandic D P. Quaternion-valued short-term joint forecasting of three-dimensional wind and atmospheric parameters. *Renewable Energy*, 2011, **36**(6): 1754–1760
- 104 Liu D, Wang J L, Wang H. Short-term wind speed forecasting based on spectral clustering and optimised echo state networks. *Renewable Energy*, 2015, **78**: 599–608
- 105 Haque A U, Mandal P, Kaye M E, Meng J L, Chang L C, Senjyu T. A new strategy for predicting short-term wind speed using soft computing models. *Renewable and Sustainable Energy Reviews*, 2012, **16**(7): 4563–4573
- 106 Yesilbudak M, Sagioglu S, Colak I. A novel implementation of kNN classifier based on multi-tupled meteorological input data for wind power prediction. *Energy Conversion and Management*, 2017, **135**: 434–444
- 107 Ramirez-Rosado I J, Fernandez-Jimenez L A, Monteiro C, Sousa J, Bessa R. Comparison of two new short-term wind-power forecasting systems. *Renewable Energy*, 2009, **34**(7): 1848–1854
- 108 De Giorgi M G, Ficarella A, Tarantino M. Assessment of the benefits of numerical weather predictions in wind power forecasting based on statistical methods. *Energy*, 2011, **36**(7): 3968–3978
- 109 Chen N Y, Qian Z, Nabney I T, Meng X F. Wind power forecasts using Gaussian processes and numerical weather prediction. *IEEE Transactions on Power Systems*, 2014, **29**(2): 656–665
- 110 Fang S C, Chiang H D. A high-accuracy wind power forecasting model. *IEEE Transactions on Power Systems*, 2017, **32**(2): 1589–1590
- 111 Salcedo-Sanz S, Pérez-Bellido Á M, Ortiz-García E G, Portilla-Figueras A, Prieto L, Paredes D. Hybridizing the fifth generation mesoscale model with artificial neural networks for short-term wind speed prediction. *Renewable Energy*, 2009, **34**(6): 1451–1457
- 112 Cheng W Y Y, Liu Y B, Liu Y W, Zhang Y X, Mahoney W P, Warner T T. The impact of model physics on numerical wind forecasts. *Renewable Energy*, 2013, **55**: 347–356

- 113 Pinson P, Kariniotakis G. Conditional prediction intervals of wind power generation. *IEEE Transactions on Power Systems*, 2010, **25**(4): 1845–1856
- 114 Ghadi M J, Gilani S H, Afrakhte H, Baghrmian A. A novel heuristic method for wind farm power prediction: a case study. *International Journal of Electrical Power and Energy Systems*, 2014, **63**: 962–970
- 115 Zhao P, Wang J F, Xia J R, Dai Y P, Sheng Y X, Yue J. Performance evaluation and accuracy enhancement of a day-ahead wind power forecasting system in China. *Renewable Energy*, 2012, **43**: 234–241
- 116 Poncela M, Poncela P, Perán J R. Automatic tuning of Kalman filters by maximum likelihood methods for wind energy forecasting. *Applied Energy*, 2013, **108**: 349–362
- 117 Yesilbudak M, Sagioglu S, Colak I. A new approach to very short term wind speed prediction using k -nearest neighbor classification. *Energy Conversion and Management*, 2013, **69**: 77–86
- 118 Guo Z H, Chi D Z, Wu J, Zhang W Y. A new wind speed forecasting strategy based on the chaotic time series modelling technique and the Apriori algorithm. *Energy Conversion and Management*, 2014, **84**: 140–151
- 119 Bouzgou H, Benoudjit N. Multiple architecture system for wind speed prediction. *Applied Energy*, 2011, **88**(7): 2463–2471
- 120 Togelou A, Sideratos G, Hatzigargyriou N D. Wind power forecasting in the absence of historical data. *IEEE Transactions on Sustainable Energy*, 2012, **3**(3): 416–421
- 121 Sideratos G, Hatzigargyriou N D. Probabilistic wind power forecasting using radial basis function neural networks. *IEEE Transactions on Power Systems*, 2012, **27**(4): 1788–1796
- 122 Sideratos G, Hatzigargyriou N D. An advanced statistical method for wind power forecasting. *IEEE Transactions on Power Systems*, 2007, **22**(1): 258–265
- 123 Sideratos G, Hatzigargyriou N D. Wind power forecasting focused on extreme power system events. *IEEE Transactions on Sustainable Energy*, 2012, **3**(3): 445–454
- 124 Amjady N, Keynia F, Zareipour H. Wind power prediction by a new forecast engine composed of modified hybrid neural network and enhanced particle swarm optimization. *IEEE Transactions on Sustainable Energy*, 2011, **2**(3): 265–276
- 125 Mahoney W P, Parks K, Wiener G, Liu Y B, Myers W L, Sun J Z, et al. A wind power forecasting system to optimize grid integration. *IEEE Transactions on Sustainable Energy*, 2012, **3**(4): 670–682
- 126 Alessandrini S, Sperati S, Pinson P. A comparison between the ECMWF and COSMO ensemble prediction systems applied to short-term wind power forecasting on real data. *Applied Energy*, 2013, **107**: 271–280
- 127 Bessa R J, Miranda V, Botterud A, Wang J H, Constantinescu E M. Time adaptive conditional kernel density estimation for wind power forecasting. *IEEE Transactions on Sustainable Energy*, 2012, **3**(4): 660–669
- 128 Giebel G, Brownsword R, Kariniotakis G, Denhard M, Draxl C. *The State-of-the-Art in Short-Term Prediction of Wind Power: A Literature Overview* (2nd edition). ANEMOS, 2011.
- 129 Wang J Z, Hu J M, Ma K L, Zhang Y X. A self-adaptive hybrid approach for wind speed forecasting. *Renewable Energy*, 2015, **78**: 374–385
- 130 Catalão J P S, Pousinho H M I, Mendes V M F. Short-term wind power forecasting in Portugal by neural networks and wavelet transform. *Renewable Energy*, 2011, **36**(4): 1245–1251
- 131 Osorio G J, Matias J C O, Catalão J P S. Short-term wind power forecasting using adaptive neuro-fuzzy inference system combined with evolutionary particle swarm optimization, wavelet transform and mutual information. *Renewable Energy*, 2015, **75**: 301–307
- 132 Pousinho H M I, Mendes V M F, Catalão J P S. A hybrid PSO-ANFIS approach for short-term wind power prediction in Portugal. *Energy Conversion and Management*, 2011, **52**(1): 397–402
- 133 Catalão J P S, Pousinho H M I, Mendes V M F. Hybrid wavelet-PSO-ANFIS approach for short-term wind power forecasting in Portugal. *IEEE Transactions on Sustainable Energy*, 2011, **2**(1): 50–59
- 134 Blonbou R, Monjoly S, Dorville J F. An adaptive short-term prediction scheme for wind energy storage management. *Energy Conversion and Management*, 2011, **52**(6): 2412–2416
- 135 Bessa R J, Miranda V, Botterud A, Zhou Z, Wang J. Time-adaptive quantile-copula for wind power probabilistic forecasting. *Renewable Energy*, 2012, **40**(1): 29–39
- 136 Bilgili M, Sahin B, Yasar A. Application of artificial neural networks for the wind speed prediction of target station using reference stations data. *Renewable Energy*, 2007, **32**(14): 2350–2360
- 137 Mohandes M A, Halawani T O, Rehman S, Hussain A A. Support vector machines for wind speed prediction. *Renewable Energy*, 2004, **29**(6): 939–947
- 138 Fadare D A. The application of artificial neural networks to mapping of wind speed profile for energy application in Nigeria. *Applied Energy*, 2010, **87**(3): 934–942
- 139 Weekes S M, Tomlin A S. Comparison between the bivariate Weibull probability approach and linear regression for assessment of the long-term wind energy resource using MCP. *Renewable Energy*, 2014, **68**: 529–539
- 140 Weekes S M, Tomlin A S. Data efficient measure-correlate-predict approaches to wind resource assessment for small-scale wind energy. *Renewable Energy*, 2014, **63**: 162–171
- 141 Lackner M A, Rogers A L, Manwell J F. The round robin site assessment method: a new approach to wind energy site assessment. *Renewable Energy*, 2008, **33**(9): 2019–2026
- 142 Ramasamy P, Chandel S S, Yadav A K. Wind speed prediction in the mountainous region of India using an artificial neural network model. *Renewable Energy*, 2015, **80**: 338–347

- 143 Chen Ying, Sun Rong-Fu, Wu Zhi-Jian, Ding Jie, Chen Zhi-Bao, Ding Yu-Yu. A regional wind power forecasting method based on statistical upscaling approach. *Automation of Electric Power Systems*, 2013, **37**(7): 1–5
(陈颖, 孙荣富, 吴志坚, 丁杰, 陈志宝, 丁宇宇. 基于统计升尺度方法的区域风电场群功率预测. *电力系统自动化*, 2013, **37**(7): 1–5)
- 144 Lazić L, Pejanović G, Živković M. Wind forecasts for wind power generation using the Eta model. *Renewable Energy*, 2010, **35**(6): 1236–1243
- 145 Al-Yahyai S, Charabi Y, Al-Badi A, Gastli A. Nested ensemble NWP approach for wind energy assessment. *Renewable Energy*, 2012, **37**(1): 150–160
- 146 Cassola F, Burlando M. Wind speed and wind energy forecast through Kalman filtering of numerical weather prediction model output. *Applied Energy*, 2012, **99**: 154–166
- 147 Lobo M G, Sanchez I. Regional wind power forecasting based on smoothing techniques, with application to the Spanish peninsular system. *IEEE Transactions on Power Systems*, 2012, **27**(4): 1990–1997
- 148 Kou P, Gao F, Guan X H. Sparse online warped Gaussian process for wind power probabilistic forecasting. *Applied Energy*, 2013, **108**: 410–428
- 149 Kou P, Liang D L, Gao F, Gao L. Probabilistic wind power forecasting with online model selection and warped Gaussian process. *Energy Conversion and Management*, 2014, **84**: 649–663
- 150 Sailor D J, Hu T, Li X, Rosen J N. A neural network approach to local downscaling of GCM output for assessing wind power implications of climate change. *Renewable Energy*, 2000, **19**(3): 359–378
- 151 Mabel M C, Fernandez E. Analysis of wind power generation and prediction using ANN: a case study. *Renewable Energy*, 2008, **33**(5): 986–992
- 152 Weekes S M, Tomlin A S, Vosper S B, Skea A K, Gallani M L, Standen J J. Long-term wind resource assessment for small and medium-scale turbines using operational forecast data and measure-correlate-predict. *Renewable Energy*, 2015, **81**: 760–769
- 153 Dinler A. A new low-correlation MCP (measure-correlate-predict) method for wind energy forecasting. *Energy*, 2013, **63**: 152–160
- 154 Wan J, Ren G R, Liu J F, Hu Q H, Yu D R. Ultra-short-term wind speed prediction based on multi-scale predictability analysis. *Cluster Computing*, 2016, **19**(2): 741–755
- 155 Jiang Z Y, Jia Q S, Guan X H. Optimization of sensor location for improving wind power prediction accuracy. In: Proceedings of the 13th IEEE Conference on Automation Science and Engineering (CASE). Xi'an, China: IEEE, 2017. 1220–1225
- 156 Guan X L, Xu Z B, Jia Q S, Liu K, Zhou Y D. Cyber-physical model for efficient and secured operation of CPES or energy Internet. *Science China Information Sciences*, 2018, **61**(11): 110201
- 157 Jia Q S, Wu J J. On distributed event-based optimization for shared economy in cyber-physical energy systems. *Science China Information Sciences*, 2018, **61**(11): 110203



姜兆宇 清华大学自动化系智能与网络化系统研究中心博士研究生. 2014 年获得清华大学学士学位. 主要研究方向为信息物理融合能源系统的数据分析与预测, 系统建模与优化. E-mail: zy-jiang14@mails.tsinghua.edu.cn
(JIANG Zhao-Yu Ph.D. candidate at the Center for Intelligent and Networked Systems, Department of Automation, Tsinghua University. He received his bachelor degree from Tsinghua University in 2014. His research interest covers data analysis and forecasting, system modeling and optimization of cyber physical energy system.)



贾庆山 清华大学自动化系智能与网络化系统研究中心副教授. 2006 年获得清华大学控制科学与工程专业博士学位. 主要研究方向为离散事件动态系统理论与应用, 基于仿真的复杂系统性能评价与优化. 本文通信作者. E-mail: jiaqs@tsinghua.edu.cn
(JIA Qing-Shan Associate professor

at the Center for Intelligent and Networked Systems, Department of Automation, Tsinghua University. He received his Ph.D. degree in control science and engineering from Tsinghua University in 2006. His research interest covers theories and applications of discrete event dynamic systems, simulation-based performance evaluation, and optimization of complex systems. Corresponding author of this paper.)



管晓宏 中国科学院院士, 长江学者特聘教授, 西安交通大学电子信息工程学院院长, 清华大学智能与网络化系统研究中心讲席教授组成员. 1982 年和 1985 年获得清华大学控制工程专业学士和硕士学位, 1993 年获得美国康涅狄格大学电气工程专业博士学位. 主要研究方向为复杂网络系统, 包括智能电网, 生产制造系统以及电力市场的规划和调度.

E-mail: xhguan@tsinghua.edu.cn
(GUAN Xiao-Hong Academician of Chinese Academy of Sciences, distinguished professor of Changjiang Scholars, Dean of the School of Electronic and Information Engineering, Xi'an Jiaotong University, members of chair professor group of the Center for Intelligent and Networked Systems, Department of Automation, Tsinghua University. He received his bachelor and master degrees in control engineering from Tsinghua University in 1982 and 1985, and Ph.D. degree in electrical engineering from University of Connecticut, USA, in 1993, respectively. His research interest covers complex networked systems including smart power grids, planning and scheduling of electrical power, manufacturing systems, and electric power markets.)